

3. ETL 4. Crawling		ETL(Extract, Transform, Load)은 경형 데이터를 변환하고 적재하는 기술로, 반경형 데이터 수집보다는 경형 데이터 처리에 적합하다.
13. 데이터 변환에 대한 설명으로 옳은 것은? 1. 데이터 유형을 변환하거나 데이터 분석이 용이한 형태로 변환하는 과정 2. 결측값 변환, 이상값 제거, 노이즈 데이터를 교정하는 과정 3. 데이터 분석이 용이하도록 기존 또는 유사 데이터를 연계, 통합하는 과정 4. 레거시 시스템(Legacy system)의 데이터와 함께 분석이 필요한 경우 수형		데이터 변환(Data Transformation)은 데이터를 분석 가능한 형태로 변환하는 작업으로, 포맷 변경, 스케일링 등이 포함된다. 결측값 변환, 이상값 제거는 데이터 정제 과정에 해당 데이터 연계 및 통합은 데이터 통합(integration) 과정 레거시 시스템 데이터 분석은 특정 시스템과 관련된 작업
14. 다음 중 데이터 비식별화 방법에 대한 설명으로 가장 적절하지 않은 것은? 1. 데이터 마스킹 : 개인식별이 가능한 데이터에 적절적으로 식별할 수 있는 다른 값으로 대체 2. 데이터 삭제 : 개인정보 식별이 가능한 특정 데이터를 삭제 3. 데이터 병주화 : 단일 식별 정보를 해당 그룹의 대표값으로 변환하거나 구간값으로 변환 4. 승계치리 : 개인정보에 대해 통계값을 적용해 특정 개인을 판단할 수 없도록 함		데이터 마스킹은 비식별화 기법이 있지만, "적절적으로 식별할 수 있는 다른 값으로 대체"라는 표현이 옳지 않다. 마스킹은 원본을 특정 규칙에 따라 가리는 방식이므로, 암호화나 난수 대체 등과 구별된다. 특정 데이터를 삭제하는 기법 데이터를 그룹으로 변환 개별 데이터를 집계하여 개인을 특정할 수 없게 하는 기법 승계치리는 개인정보를 집계하여 특정 개인을 식별할 수 없도록 하는 방법이지만 , 데이터 비식별화 방법으로는 적절하지 않습니다 .
15. 비식별화 프라이버시 모델 중 특정한 추론이 안 된다고 해도 민감한 정보의 다양성을 높여 추론 가능성을 낮추는 기법은? 1. k-익명성 2. t-다양성 3. t-근접성 4. k-민감성		같은 그룹에 k명 이상 존재하도록 하는 기법 동일한 그룹 내에서 민감한 값이 일정 수준 이상 다양하도록 유지하는 방식으로, 특정 값의 빈도를 낮춰 개인의 정보 추론을 어렵게 만든다. 민감한 속성이 전체 데이터 분포와 유사하도록 조정 존재하지 않는 개념
16. 다음을 설명하는 품질 특성을 고르시오. 필수항목에 누락이 없어야 한다. 예) 고객의 아이디는 NULL일 수 있다. 1. 완전성 2. 유일성 3. 일관성 4. 신뢰성		필수 데이터가 특정값이 존재하지를 의미한다. 데이터가 중복되지 않도록 관리 데이터 간 논리적인 일관성 유지 데이터의 정확성과 안정성
17. 경형 데이터의 품질 기준에 대한 설명으로 가장 적절하지 않은 것은? 1. 필수항목에는 누락이 없어야 하는 특성 2. 규정된 조건에서 사용될 때, 사용지에 의해 이해되고, 신뢰할 수 있게 하는 정도 3. 데이터 항목은 정해진 데이터 유효 범위 및 도메인을 충족해야 하는 특성 4. 데이터가 지켜야 할 구조, 값 등이 일관되게 정의되어야 하며 일치해야 하는 특성		완전성 해당 설명은 사용자 경험(UX)과 관련된 개념으로, 데이터 품질 기준과는 다소 거리가 있다. 정확성 일관성
18. 데이터 품질진단으로 도출할 수 있는 질문은 무엇인가? 1. 왜 발생했는가? 2. 언제 할 것인가? 3. 사건이 일어날 것인가? 4. 어떻게 대응할 것인가?		원인 분석 과정 실행 계획과 관련 예측 분석 문제 해결 단계
19. 전통적 분석 환경에서의 ETL에 대한 설명으로 알맞지 않은 것은? 1. ETL은 Extract, Transform, Load 세 단어의 축약어로 데이터 소스시스템 및 환경으로부터 데이터를 추출하여 비즈니스 데이터로 변환 후 데이터 마트, 데이터 웨어하우스, ODS(Online Data Store)로 적재한다. 2. ETL 구현을 위해 일괄 ETL(Batch ETL) 실시간 ETL(Real Time ETL)로 구분할 수 있다. 3. 대용량 데이터 처리를 위해 MPP(작업 단계에서 다수의 프로세서가 동시 처리할 수 있게 하는 병렬처리 프로 세스)를 지원한다. 4. ETL은 중간 단계에 저장하는 역할을 한다.		배치 ETL과 실시간 ETL 방식이 존재 MPP 지원으로 대용량 데이터 처리 가능 ETL은 데이터를 추출하고 변환한 후 최종적으로 데이터 웨어하우스나 데이터 마트에 적재하는 과정이지, 중간 저장을 목적으로 하지 않는다.
20. 비정형 데이터 저장방식으로 알맞지 않은 것은? 1. 단어, 문장 2. 음성 데이터는 정격이므로 y = f(x)의 형태 3. 이미지는 RGB픽셀 4. 동영상은 스트리밍 방식		음성 데이터는 정격이지 않으며 시간에 따라 변화하는 시계열 데이터의 특성을 갖는다. 즉, 수학적 함수 형태(y=f(x))로 단순 표현하기 어렵다.
21. 이상값 탐지를 위한 상자그림(Boxplot)에서 측정 불가능한 항목은 무엇인가? 1. 제1사분위수 2. 사분위수 범위(IQR) 3. 평균값 4. 중앙값(Median)		상자그림(Boxplot)은 데이터의 사분위수(제1, 제3사분위수), 중앙값, 이상값 등을 나타내지만, 평균값(Mean)은 직접적으로 표시되지 않는다.
22. 레코 기법에 대한 설명으로 가장 부적절한 것은? 1. 전진선택법은 변수를 알 수 없는 상태로 시작하여 반복할 때마다 가장 중요한 변수를 추가함으로써 더 이상 성능 향상이 없을 때까지 변수를 추가하는 방법이다. 2. 전진선택법은 변수값의 작은 변동에도 그 결과가 유지되어 안정성이 높다. 3. 후진제거법은 모든 변수를 가지고 시작하고 가장 덜 중요한 변수를 하나씩 제거하면서 모델의 성능을 향상시키는 기법이다. 4. 단계별 선택법은 전진과 후진제거법을 결합하여 사용하는 기법이다.		변수 추가에 따라 모델이 변동할 수 있어 안정성이 낮다. 데이터에 따라 선택되는 변수가 달라질 수 있다.
23. 대표적인 차원축소 기법에 대한 다음의 설명 중 옳지 않은 것은? 1. 주성분분석은 여러 변수들의 선형 결합으로 이루어진 주성분이라는 새로운 변수를 만들어 기존의 변수들을 요약하여 축소하며, 각 주성분 간에 우선순위가 없이 대응한다. 2. 다차원회도법은 데이터 속에 잠재해 있는 패턴, 구조를 찾아내어 소수 차원의 공간에 객체 간 근접성을 시각화하는 통계 기법으로 차원축소에 사용될 수 있다. 3. 차원축소 기법 중 하나인 요인분석은 여러 개의 변수들로 이루어진 데이터에서 변수들 간의 상관관계를 고려 하여 서로 유사한 변수들을 묶어 새로운 잠재요인을 추출해내는 분석방법이다. 4. t-SNE는 데이터에서 지역 인접성을 보존하려고 시도하는 차원축소 알고리즘으로, 비선형적이며 비결정적이다.		PCA의 주성분들은 중요도(분산 설명량)에 따라 순위가 정해진다. 1주성분이 가장 중요한 정보를 담고 있으며, 이후 주성분들은 중요도가 낮아진다.
24. 아래의 설명 중 파생변수의 추가방법에 해당되는 것을 모두 고르시오. ㄱ. 한 값으로부터 특징들을 추출한다. ㄴ. 한 레코드 내의 값들을 결합한다. ㄷ. 다른 데이터들의 부가적인 정보를 참조한다. ㄹ. 거래 레코드를 분리한다. ㅁ. 복잡한 표현방식으로 변환한다. 1. ㄱ, ㄷ 2. ㄴ, ㅁ 3. ㄱ, ㄴ, ㄷ 4. ㄱ, ㄴ, ㅁ		한 값에서 특징 추출(예: 날짜 → 요일) 한 레코드 내 값 결합(예: 키, 몸무게 → BMI) 다른 데이터들 정보 참조(예: 고객 정보 + 거래 정보) 데이터 통합에 해당합니다. 거래 레코드 분리 → 데이터 정제 과정에 가깝음, 데이터 분할에 해당 복잡한 표현 변환 → 데이터 인코딩 과정

25. 불균형 데이터 처리방법으로 적절하지 않은 것은?		
1. 언더샘플링		
2. 오버샘플링		
3. SMOTE		
4. 임베딩도 기법		가상의 데이터를 생성하여 오버샘플링 특징 선택(Feature Selection) 방법으로, 불균형 데이터 처리와는 관련이 없다.
26. 다음 중 오버샘플링 (Over Sampling)에 대한 설명으로 옳지 않은 것은?		
1. 장치가 손실되지 않는다는 장점이 있다.		
2. 데이터의 수를 증가시키므로 복제되는 데이터에 분류기가 과적합될 수 있는 단점이 있다.		
3. 오버샘플링 기법에는 Resampling, SMOTE, Borderline SMOTE가 있다.		
4. 데이터의 크기가 클 때 효과적이며 계산 시간이 감소한다.		오버샘플링은 데이터 양을 증가시키므로 계산량이 증가하고 시간이 더 걸릴 수 있다.
27. 상관관계 분석에 대한 설명으로 가장 부적절한 것은?		
1 두 개의 변수 간의 직선관계의 선형성과 산점도로 확인할 수 있다.		
2 양(+)의 상관관계는 두 변수가 동반 증가되는 것이며, 음(-)의 상관관계는 두 변수의 값이 반대로 증감하는 것이다.		
3 -1~+1 사이의 값으로 -1과 +1은 완전한 비선형관계를 의미한다.		상관계수 -1과 +1은 완전한 선형관계를 의미하며, 비선형 관계와는 다르다.
4 두 변수의 선형관계 측정을 위한 수치로 공분산 상관계수를 사용한다.		
28. 상관관계 분석에 대한 설명으로 가장 부적절한 것은? 프로야구 선수 A의 연도별 홈런 개수를 조사하였다. 주어진 자료가 {1, 2, 5, 4, 7, 10}일 때, 자료의 중앙값을 계산하시오.		
1. 중앙값 = 4.2		
2. 중앙값 = 4.3		
3. 중앙값 = 4.4		
4. 중앙값 = 4.5		중앙값 = (4 + 5) / 2 = 4.5
30. 다음에서 설명하는 다변량 데이터 탐색방법으로 가장 알맞은 것은?		
()는 하나의 변수를 하나의 세로축으로 평행하게 배치하며, 한 축의 첫부분은 각 변수의 (패링되는 하나의 축) 최대값 아래 부분은 각 변수의 최소값을 나타낸다. 변수를 표시한 세로축 여러 개를 나란히 늘어놓음으로써 한 번에 많은 데이터를 비교하기에 유용한 그래프이다.		변수 간 2차원 산점도 여러 개의 변수를 세로축으로 나열하여 데이터 비교에 유용한 시각화 방법이다. 얼굴 모양을 이용한 시각화 여러 개의 작은 차트를 나열
1. 산점도 행렬		
2. 행렬차크그래프		
3. 체르노프페이스		
4. 스몰멀티플츠		
31. 다음에서 설명하는 표본추출 방법은 무엇인가?		
모집단의 전체에 번호를 붙여 놓고 첫 번째 선택 후 3개 간격으로 샘플을 추출한다.		
ex. 1, 2, 3 / 4, 5, 6 / 7, 8, 9 에서 1, 4, 7을 추출		
1. 단순확률표본추출		
2. 층화확률표본추출		
3. 계층표본추출		
4. 집락추출		
32. 핸드폰 생산공장에서 핸드폰을 생산하는데 A, B, C라인을 사용한다. 생산량의 10%를 A라인, 30%를 B라인, 60%를 C라인에서 생산하고, A라인의 불량률은 1%, B라인의 불량률은 2%, C라인의 불량률은 3%라고 했을 때, A 라인에서 불량률이 발생할 확률은?		불량품이 발생할 확률은 전체 불량품 중 A라인에서 나온 비율을 구해야 한다. 베이즈 정리를 적용하면: $P(A 불량) = \frac{P(불량 A)P(A)}{P(불량)}$
1. 0.04		
2. 0.017		
3. 0.4		
4. 0.17		주어진 값: $P(A) = 0.1$ $P(B) = 0.3$ $P(C) = 0.6$ $P(불량 A) = 0.01$ $P(불량 B) = 0.02$ $P(불량 C) = 0.03$ 전체 불량 확률: $P(불량) = (0.1 \times 0.01) + (0.3 \times 0.02) + (0.6 \times 0.03) = 0.027$ A라인에서 불량 발생 확률: $P(A 불량) = \frac{0.1 \times 0.01}{0.027} = \frac{0.001}{0.027} \approx 0.017$
33. 확률분포에 대한 설명으로 가장 알맞지 않은 것은?		
1. 이산확률분포는 이항분포, 초기하분포, 포아송분포가 해당된다.		
2. 연속확률분포는 분포, F분포, t분포, 정규분포가 있다.		
3. 확률변수 X가 "개"의 이산값 (x1, x2, ..., xn) 을 가지며 각 값들이 확률 확률이 동일한 경우, 이 확률변수를 이산균등분포를 따른다고 한다.		
4. 베르누이분포는 '성공'에 해당하는 사건이 발생할 확률이 p인 독립은 시행을 2번 반복해서 시행하여 일어난 두 가지 결과에 의해 그 값이 각각 0과 1로 결정되는 확률분포이다.		베르누이 분포는 성공(1)과 실패(0) 중 하나만 나오는 단일 시행에 대한 확률 분포이다.
34. 이산확률분포가 아닌 것은?		
1. 이항분포		
2. 균등분포		
3. 정규분포		성공/실패 같은 이산값을 가짐. 연속형과 이산형이 있지만 일반적으로 이산확률분포에도 해당함. 정규분포는 연속확률분포로, 실수 값을 가짐. 일정 시간 동안 사건이 발생하는 횟수에 대한 이산확률분포.
4. 포아송분포		
35. 아래의 사례의 경우 사용할 수 있는 연속확률분포는 ?		

