

15. 재현 자료(Synthetic data)에 대한 설명으로 옳은 것은? 1. 원본과 통계적으로 유사하나 가상으로 다시 만들어진 데이터이다. 2. 완전 재현 데이터는 민감한 정보에 대해서만 재현 데이터로 대체하는 방식이다. 3. 부분 재현 데이터는 정보 모두를 재현 데이터로 생성하는 방식이다. 4. 암호화 상태에서 데이터를 결합하고 연산/분석 등이 가능하다. 16. 다음 중 데이터 비식별화 방법에 대한 설명으로 가장 적절하지 않은 것은? 1. 데이터 마스킹 : 개인정보가 가능한 데이터에 직접적으로 식별할 수 없는 다른 값으로 대체 2. 데이터 삭제 : 개인정보 식별이 가능한 특정 데이터값을 삭제 3. 데이터 범주화 : 단일 식별 정보를 해당 그룹의 대표값으로 변환하거나 구간값으로 변환 4. 총계처리 : 개인정보에 대해 통계값을 적용해 특정 개인을 판단할 수 없도록 함 17. 다음 중 민감정보가 아닌 것을 고르시오. 1. 종교 2. 신용등급 3. 정치성향 4. 인종정보 18. 전통적 분석 환경에서의 ETL에 대한 설명으로 알맞지 않은 것은? 1. ETL은 Extract, Transform, Load 세 단어의 축약어로 데이터 소스시스템 및 환경으로부터 데이터를 추출하여 비즈니스 데이터로 변환 후 데이터 마트, 데이터 웨어하우스, ODS로 적재한다. 2. ETL 구현을 위해 일괄 ETL(Batch ETL) 실시간 ETL(Real Time ETL)로 구분할 수 있다. 3. 대용량 데이터 처리를 위해 MPP(작업 단계에서 다수의 프로세서가 동시 처리할 수 있게 하는 병렬처리 프로세스)를 지원한다. 4. ETL은 중간 단계에 저장하는 역할을 한다. 19. 데이터 웨어하우스(DW)의 특징으로 옳지 않은 것은? 1. 주제 중심 2. 통합 구조 3. 시계열성 4. 휘발성 20. NoSQL의 유형별 종류로 옳게 짝지어진 것을 고르시오. 1. Document-oriented: Oracle Berkeley DB, Voldmorte 2. Key-Value: Redis, HyperTable 3. Column-Oriented: Cassandra, Google BigTable 4. Graph: Neo4j, HBase 21. 데이터 정제에 대한 설명으로 옳지 않은 것을 고르시오. 1. 정제는 데이터 전처리의 한 과정이다. 2. 결측값을 채우고 이상값을 삭제하거나 대체한다. 3. 데이터의 누락값, 불일치, 오류의 수정 및 숫자나 날짜등의 형식에 대해 일관성 유지를 수행하게 된다. 4. 데이터 정제는 1회성으로 완료된다. 22. PCA(주성분분석) 기법에 대한 설명으로 옳은 것은? 1. 데이터 처리 기법이다. 2. 다수 변수들을 변수들 간의 상관관계를 분석하여 공통 자원들을 통해 축약한다. 3. 비유사성을 측정하여 2차원 또는 3차원 공간상에 점으로 표현한다. 4. 상관행렬과 공분산행렬을 이용한다. 23. 다음 중 요인분석(Factor Analysis)에 해당되는 것을 모두 고르시오. 가. 데이터에 관찰할 수 있는 잠재적 변수가 존재한다고 가정한다. 나. 다수 변수들을 변수 간의 상관관계를 분석하고 공통 자원으로 축약하는 통계 기법이다. 다. 상관계수 ±3을 벗어나는 자료는 부적합하다. 라. 사회과학, 설문조사 등에 많이 활용되는 기법이다. 1. 가 2. 가, 나 3. 가, 다, 라 4. 가, 나, 다, 라 24. Box-Cox 변환에 대한 설명으로 옳지 않은 것을 고르시오. 1. 변수 변환기법이다. 2. 로그변환을 이용한다. 3. 자원축소 기법이다. 4. 거듭곱변환을 이용한다. 25. 변수 변환기법 중 스케일링 기법이 아닌 것은? 1. 범주화 2. 최소최대 정규화 3. 표준화 4. 최대-절대값 정규화 26. 불균형 데이터에 대한 설명으로 옳지 않은 것은? 1. 불균형 데이터가 존재할 경우 많은 비율을 가진 집단의 정확도(Accuracy)가 높아지므로 모형의 성능 판별이 어려워지게 된다. 2. 작은 비율을 가진 집단의 재현율(Recall)은 작아지는 현상이 발생할 수 있다. 3. 변수가 가진 데이터에서 각 집단에 속하는 데이터의 수가 동일하지 않은 상태이다. 4. 기존 변수에 특정 조건 혹은 함수 등을 활용하여 만들거나 기존 변수들을 조합하여 새롭게 만들어진 과정이다. 27. 상관관계 분석에 대한 설명으로 가장 부적절한 것은? 1. 두 개의 변수 간의 직선관계의 선형성과 산포도로 확인할 수 있다. 2. 양(+)의 상관관계는 두 변수가 동반 증가하는 것이며, 음(-)의 상관관계는 두 변수의 값이 반대로 증감하는 것이다. 3. -1 ~ +1 사이의 값으로 -1과 +1은 완전한 비선형관계를 의미한다. 4. 두 변수의 선형관계 측정을 위한 수치로 공분산 상관계수를 사용한다.	데이터 마스킹은 직접 식별이 불가능하도록 변환하는 기법이지만, 특정 값으로 대체하는 것만을 의미하지는 않습니다. 데이터 범주화는 단일 식별 정보를 그룹의 대표값으로 변환하는 것이 아니라, 구간값으로 변환하는 것을 의미합니다. 따라서 이 설명은 적절하지 않습니다. ETL은 데이터를 추출, 변환, 적재하는 과정이며, 단순 저장하는 역할이 아닙니다. 데이터 웨어하우스(DW)는 휘발성이 아니라, 지속적인 데이터 저장과 분석을 위한 비휘발성 시스템입니다. Document-Oriented: MongoDB, CouchDB Key-Value: Redis, Riak Graph: Neo4j, ArangoDB 데이터 정제는 지속적인 과정이며, 데이터가 추가되거나 업데이트될 때마다 반복적으로 수행해야 한다. PCA는 변수 간의 상관관계를 분석하여 차원을 축소하는 기법이다. 2차원 또는 3차원 공간에 표현하는 것은 다차원 척도법(MDS)과 관련 있다. 상관행렬과 공분산행렬을 이용하는 것은 맞지만, 이는 PCA의 일부 과정이지 PCA의 본질적인 설명은 아니다. 요인분석은 관찰할 수 없는 잠재 변수를 가정하며, 다수의 변수를 상관관계를 기반으로 축소하는 통계 기법이다. 상관계수 ±3을 벗어나는 자료는 부적합하다는 내용은 틀렸다(상관계수는 -1~1 사이의 값). 사회과학, 설문조사 등에 많이 활용되지만, 이 자체가 요인분석의 필수 요소는 아니다. Box-Cox 변환은 자원 축소 기법이 아니라 데이터 변환(정규화) 기법이다. 범주화는 데이터를 그룹으로 나누는 과정이며, 스케일링(정규화, 표준화 등)과는 다르다. 4번은 새로운 변수를 만드는 방법으로, 불균형 데이터 자체의 개념과는 다르다. -1과 +1은 완전한 선형관계를 의미하며, 비선형 관계를 의미하지 않는다.
--	--

라. 바둑에서 인간의 데이터를 사용하지 않고, 규칙만으로 보상을 통한 학습 사용	알파고는 인간 데이터를 사용하지 않고, 보상 기반으로 학습하는 강화학습을 사용함.
1. RNN, CNN, RNN&CNN, 강화학습	
2. CNN, RNN, RNN&CNN, 강화학습	
3. 강화학습, CNN, RNN, RNN&CNN	
4. RNN, 강화학습, RNN&CNN, CNN	
42. 다음 중 파라미터 선택에 대한 내용이 아닌 것은?	
1. 사람의 수작업으로 측정되고 결정됨	
2. 모델 내부에서 확인이 가능한 변수로 데이터를 통해 산출 가능한 값	
3. 예측을 수행할 때 모델에 의해 요구되어지는 값	
4. 측정되거나 데이터로부터 학습됨	
43. 아래 설명의 문제에 대한 해결 기법으로 가장 알맞지 않은 것은?	
회귀분석에서 독립변수를 강해 강한 상관관계가 나타나는 문제이다. 이러한 문제가 존재하면 경쾌한 회귀계수의 추정이 어렵다.	
1. 상관관계가 높은 독립변수 중 하나 혹은 일부를 제거한다.	
2. 변수를 변형시키면 안 되고, 기존 관측치를 그대로 이용한다.	
3. 자료를 수집하는 현장의 상황을 보아 상관관계의 이유를 파악하여 해결한다.	
4. 주성분분석을 이용한 대각행렬의 형태로 공선성을 없애 준다.	
44. 다중회귀모형(모형)의 통계적 유의성 확인 방법은 무엇인가?	
1. F통계량을 확인한다	
2. t검정을 실시한다	
3. ANOVA를 수행한다.	
4. 교차검증을 실시한다.	
45. 외삽결정나무의 회귀트리(Regression Tree) 모형(모형)을 만들 때의 분류 기준은 무엇인가?	
1. t통계량	
2. 분산감소량, F통계량	
3. 엔트로피지수	
4. 지니지수, 카이제곱통계량	
46. 다음 중 활성화 함수의 설명으로 적절한 것?	
1 로지스틱회기 모델에서의 회귀계수와 유사하게 해석한다.	
2 L2 penalty를 사용한다.	
3 선형이면 의미가 없다.	
4. 시그모이드 함수가 대표적이다.	
47. 활성화 함수 중 시그모이드와 하이퍼볼릭탄젠트 (Tanh) 함수의 결과값을 순서대로 도출하시오.	
1. 0 ≤ y ≤ 1, -1 ≤ y ≤ 1	
2. -1 ≤ y ≤ 1, -1 ≤ y ≤ 1	
3. -1 ≤ y ≤ 0, -1 ≤ y ≤ 0	
4. -1 ≤ y ≤ 1, 0 ≤ y ≤ 1	
49. 서포트벡터머신 (SVM)의 설명으로 틀린 것은?	
1. 분류와 회귀분석에 사용되는 지도학습 알고리즘이다.	
2. 데이터가 사상의 공간에서 경계선과 가장 근접한 데이터를 서포트벡터라고 부른다.	
3. 테스트가 매우 쉽다.	
4. 고차원에서의 비정 추측이 어려운 경우 자원의 지주를 회피한다.	
50. 다음 중 서포트벡터머신 (SVM)의 커널 종류가 아닌 것은?	
1. 다항식 커널	
2. 회귀형 커널	
3. 가우시안 커널	
4. 시그모이드 커널	
51. 연관규칙의 "A→B"의 향상도는?	
지지도 : 3/10, P(A): 6/10, P(B): 6/10.	
1. 63%	
2. 36%	
3. 38%	
4. 83%	
52. 주성분분석 (PCA)의 공분산행렬에 대한 설명으로 옳지 않은 것은?	
1. 공분산행렬의 고유벡터는 데이터가 어떤 방향으로 분산되었는지를 나타낸다.	
2. 변수들 사이의 공분산 행렬로 나타낸 값이다.	
3. 경방행렬은 불가능하다.	
4. 전치를 시켰을 때 동일한 행렬이 나타나는 대칭행렬이다.	
53. 다음을 참고하여 데이터에 대한 주성분분석 (PCA)의 결과를 해석으로 옳은 것은?	
Importance of components: PC1 PC2 PC3 PC4 Standard deviation 30.1227 27.0528 9.07614 6.15239 Proportion of Variance 0.5157 0.4159 0.04682 0.02151 Cumulative Proportion 0.5157 0.9317 0.97849 1.00000	
1. 두 번째 주성분의 누적기여율은 93.17%이다.	
2. 최소 70%의 분산 설명력을 갖기 위한 주성분의 개수는 3개이다.	
3. 누적기여율은 세 번째 주성분의 값으로 고정되어 있다.	
4. 첫 번째 주성분으로 기준을 상을 수 있다.	
54. 다음 시계열의 요인 중 틀린 것은?	

알파고는 인간 데이터를 사용하지 않고, 보상 기반으로 학습하는 강화학습을 사용함.

파라미터는 모델 내부에서 데이터를 통해 학습되거나 측정되는 값입니다. 사람이 수작업으로 결정하는 것은 하이퍼파라미터입니다. 파라미터는 사람이 설정하는 값으로, 모델이 학습을 통해 결정하는 것은 가중치나 편향과 같은 하이퍼파라미터임.

모델 내부에서 확인 가능한 변수로 데이터를 통해 산출 가능한 값은 파라미터입니다.

상관관계가 높은 독립변수 중 하나 혹은 일부를 제거하는 것은 다중공선성 문제 해결에 적합합니다. 다중공선성이 존재하면 변수 변형(표준화, 주성분 분석 등)이나 제거가 필요함. 자료를 수집하는 현장의 상황을 보아 상관관계의 이유를 파악하여 해결하는 것도 적절한 방법입니다. 주성분분석을 이용한 대각행렬의 형태로 공선성을 없애는 것도 적절한 방법입니다.

F통계량은 모델 전체의 유의성 검정에 사용됨. t검정은 개별 변수의 유의성을 평가함. ANOVA는 집단 간 평균 차이를 검정하는 방법. 교차검증은 모델 일반화 성능을 평가하는 데 사용됨.

회귀트리는 연속형 값을 예측하며, 분산 감소량을 기준으로 최적 분할을 결정함. F통계량은 회귀분석에서 개별 계수의 유의성을 확인하는 데 사용됩니다. 회귀트리는 분산을 최소화하는 방향으로 분할합니다. 따라서 분산감소량이 주요 기준입니다. 3번(엔트로피), 4번(지니지수, 카이제곱)은 분류트리에 사용됨.

활성화 함수의 대표적인 예로 시그모이드, ReLU, Tanh 등이 있음. 로지스틱 회귀 계수와 동일함 L2 페널티는 정규화 기법 활성화 함수가 선형이면 신경망의 출을 깊게 하는 의미가 없어집니다. 활성화 함수는 신경망에서 비선형성을 추가하는 데 사용됩니다. 시그모이드 함수는 대표적인 활성화 함수 중 하나입니다.

시그모이드: 0에서 1 사이의 값 출력 / Tanh: -1에서 1 사이의 값 출력

SVM은 테스트가 쉽지 않으며, 특히 고차원 데이터에서 계산 비용이 높을 수 있습니다. SVM은 커널 트릭을 이용해 고차원 특징 공간에서 효과적으로 분류 가능하지만, 차원의 저주 자체를 해결하는 방법은 아님.

*회귀형 커널"이라는 개념은 없음.

$$\text{향상도} = \frac{\text{지지도}(A \rightarrow B)}{P(A) \times P(B)}$$
$$= \frac{3/10}{(6/10) \times (6/10)} = \frac{0.3}{0.36} = 0.8333$$

향상도(Lift)는 P(B|A) / P(B)로 계산됩니다. 여기서 P(B|A) = 지지도 / P(A) = (3/10) / (6/10) = 0.5, P(B) = 6/10 = 0.6. 따라서 향상도 = 0.5 / 0.6 = 0.83 (83%).

공분산 행렬은 항상 정방행렬이므로, 이 설명이 틀림

누적 기여율이 PC2에서 **0.9317(93.17%)**이므로 정답. 누적기여율을 보면, PC1과 PC2가 93.17%의 분산을 설명합니다. 따라서 최소 70%의 분산 설명력을 갖기 위한 주성분의 개수는 2개입니다.

