

4. 네트워크 데이터 베이스	
20. 다음 중 비경형 데이터에 관한 설명으로 틀린 것은? 1. 데이터 스키마를 지원한다. 2. 주로 DB to DB를 사용해 수집한다. 3. Nosql을 사용한다 4. 데이터 레이크보다 데이터 웨어하우스를 사용한다.	
21. 데이터 전처리 기법에 대한 설명 중 옳지 않은 것은? 1. 데이터 정제 : 결측값, 노이즈, 이상값 등 데이터 오류 요인을 제거한다. 2. 데이터 통합: 정제된 다수의 데이터를 통합한다. 3. 데이터 축소: 노이즈 제거 위해 정규화한다. 4. 데이터 변환: 정규화 등으로 분석이 편하도록 한다.	
22. 데이터 정제에 대한 설명으로 옳지 않은 것은? 1. 데이터를 사용하기 쉽게 변환 2. 결측값 대체 3. 이상값 제거 4. 노이즈 교정	
23. 결측값 처리방법에 대한 설명으로 적절하지 않은 것은? 1. 관전사제법: 결측값 부분만 없애지 않고, 결측값이 있는 데이터 전체를 삭제한다. 2. 평균대치법: 관측된 값의 평균값으로 대체한다. 3. 회귀대치법: 회귀식의 예측값으로 결측값을 대체한다. 4. 다중대치법: 통계적인 방법을 이용한다.	
24. 이상값 처리에 대한 설명으로 틀린 것은? 1. 이상값은 반도에 비해 영향력이 작으므로 분석에서는 무시한다. 2. 삭제 시 데이터가 적아지 분산은 커지고, 편향이 발생할 확률은 높아진다. 3. 결측값 처리에서 사용하는 단순대치법과 다중대치법은 사용할 수 없다.	
4. 평균값 대체도 결측값 대체와 같이 신뢰성이 저하되지 않는다.	
25. 데이터 이상값 발생 원인으로 옳지 않은 것은? 1. 측정오류 2. 처리오류	
3. 표본오류 4. 보고오류	
26. 회귀전단 시 이상값 및 영향값 탐색 방법으로 틀린 것은? 1. 라쏘회귀 2. AIC(Akaike Information Criterion) 3. 사분위수 범위 4. 레버리지(Leverage)	
28. 다음 중 연속형 변수가 아닌 것은? 1. 키 2. 실내온도 3. 성인의 혈액형 4. 책 두께	
29. 파생변수에 대한 설명으로 옳지 않은 것은? 1. 기존 변수에 특정 조건이나 함수를 활용하기도 한다. 2. 유의미한 특성이 객관적으로 반영되어야 한다. 3. 결측값으로 주변 값을 채우기도 한다. 4. 다수 필드 내에 시간 중속적인 데이터를 피해서 사용하는 방법도 있다.	
30. 최소-최대 정규화 시 세 학생의 성격(60, 70, 80) 합은? 1. 0.5 2. 1.0 3. 1.5 4. 2.0	
31. 다음 중 독립변수 12개와 종변 1개를 포함하는 모델이 있다. 변수 1개당 범주 3개씩 가질다면 회귀모수 개수는? 1. 24개 2. 25개 3. 36개 4. 37개	
32. 클래스 불균형(Class Imbalance)에 대한 설명으로 옳지 않은 것은? 1. 이상값 대체는 결측값을 처리할 경우와 같은 신뢰도 문제를 발생시키지 않는다. 2. 무게 균형(Weight Balancing)으로는 해결 불가능하다. 3. 언더샘플링 혹은 오버샘플링으로 해결할 수 있다.. 4. 클래스의 개수와는 무관하다.	
33. 다음 중 인과관계분석(Causal Analysis)에 대한 설명으로 틀린 것은? 1. 변수 간의 상관성을 확인한다. 2. 해석을 포함하고 있지 않다. 3. 이상값 파악이 용이하다. 4. 독립변수와 종속변수 간의 인과관계를 분석한 것이다.	
차원 축소 기법(PCA, 요인 분석)이나 샘플링을 통해 데이터 크기를 줄이는 과정이지, 노이즈 제거와는 직접적인 관련이 없다. 노이즈 제거는 데이터 정제의 영역이다.	
데이터 정제는 데이터를 "변환"하는 과정이 아니다. 변환은 데이터 변환(Transformation) 단계에서 수행된다. 데이터 정제는 결측값을 처리하고 이상값을 제거하는 과정이다.	
데이터의 일부만 삭제하는 것이 아니라, 결측값이 하나라도 포함된 행(row) 전체를 삭제하는 방법이다. 데이터 손실이 크기 때문에 신중하게 사용해야 한다.	
이상값을 무조건 무시하면 데이터 분석의 신뢰도가 낮아질 수 있다. 이상값이 중요한 정보일 수도 있기 때문이다. 삭제 시 데이터가 적아지 분산은 커지고, 편향이 발생할 확률은 높아진다. 단순대치법과 다중대치법은 결측값 처리 방법으로, 이상값 처리에는 일반적으로 사용되지 않는다. 평균값 대체 시 데이터의 실제 분포를 왜곡할 수 있으므로 신뢰성이 저하될 수 있다.	
이상값을 평균값으로 대체하는 것은 신뢰성이 저하될 수 있습니다. 이상값은 데이터의 분포를 왜곡할 수 있으므로, 평균값 대체는 적절하지 않을 수 있습니다.	
센서 오작동, 기기 결함 등으로 인해 발생하는 오류. 데이터 변환, 저장 과정에서 발생하는 오류. 샘플이 모집단을 제대로 대표하지 못할 때 발생하는 오류. 표본오류는 이상값 발생 원인이 아니라, 표본 추출 과정에서 발생하는 오류입니다. 일반적으로 이상값 발생 원인이라기보다는 데이터 입력 오류(입력 실수)와 관련이 있다.	
변수 선택을 수행하는 기법이며, 이상값 탐색과 직접적인 관련이 없다. 모델 선택을 위한 지표이며, 이상값 탐색과는 관계없다. 데이터의 이상치를 탐색하는 방법이지만, 회귀전단과는 관련이 적다. 회귀 분석에서 데이터 포인트가 회귀선에 미치는 영향을 측정하는 지표로, 이상값 탐색에 활용된다.	
파생변수는 기존 변수에서 새로운 변수를 생성하는 과정이지, 결측값을 채우는 과정이 아니다. 결측값 처리와는 별개 개념이다.	
각 독립변수는 범주가 3개이므로, 각 변수당 2개의 더미 변수가 필요합니다. 따라서 12개 변수에 대해 24개의 더미 변수가 필요하며, 종변 1개를 포함하면 총 25개의 회귀모수가 필요합니다. 독립변수 12개 × 각 변수의 범주 수 3개 = 36개 (공변 포함 X)	
Weight Balancing은 클래스 불균형을 해결하는 데 사용할 수 있다.	
클래스 불균형은 클래스의 개수와 직접적으로 관련이 있습니다. 특정 클래스의 샘플 수가 다른 클래스에 비해 현저히 적을 때 발생합니다.	

1. 데이터셋을 k개로 분할 2. k-1개의 검증 데이터 확보 3. 학습 데이터와 검증 데이터를 서로 다르게 지정하여 k번 반복 4. k번 각각의 성능에 대한 평균을 도출	
65. 아래 보기에 대한 설명으로 옳은 것은? 두 명의 데이터 분석가 A와 B가 있다. A와 B는 각각의 방식으로 데이터를 분석하기로 했으며, 분석 시 10개의 파라미터를 동일하게 설정하기로 결정했다.	하나의 데이터를 검증에 사용하고 나머지로 학습하는 방식이라 해당 문맥과 맞지 않는다.
1. LOOCV	데이터가 매우 적을 때 사용된다.
2. 5fold-CV	5-Fold CV(2번)나 Stratified K-fold CV(4번)는 샘플링 기법이지만, 본 문제는 오월 비교보다는 데이터의 재표본추출을 강조하고 있으므로 Bootstrap(3번)이 적절하다.
3. Bootstrap	두 명의 데이터 분석가가 동일한 파라미터를 설정하고 데이터를 분석할 때, 5-fold 교차검증은 데이터를 5개로 분할하여 각각의 분할에 대해 학습과 검증을 반복하는 방법으로, 일반화 성능을 평가하는 데 적합합니다. A와 B가 같은 파라미터 설정을 사용한다는 점에서 재표본추출(Resampling) 기법인 <Bootstrap이 적절하다.
4. Stratified K-fold CV	데이터를 반복적으로 샘플링하는 방법으로, 교차검증과는 다릅니다.
66. 콜모고로프-스미르노프(K-S) 통계량에 대한 설명으로 옳은 것을 모두 고르시오. 가. 서로 다른 두개의 집단이 동일한 분포를 이루고 있는지를 검증하는 지표 나. 비교하는 두 개의 집단 사이의 최대 거리 다. 누적분포함수(Cumulative Distribution Function, CDF)와 경험적 누적분포함수(Experience CDF 혹은 ECDF)를 사용	콜모고로프-스미르노프(K-S) 검증은 두 분포가 동일한지를 검증하는 방법이며, 누적분포함수(CDF)와 경험적 누적분포함수(ECDF)를 활용하여 두 분포 간 최대 거리를 계산한다.
1. 가 2. 가, 나 3. 나, 다 4. 가, 나, 다	
67. 다음 중 적합도 검증에 대한 설명으로 옳지 않은 것은? 1. 모델 전체의 적합성은 검증 불필요하다. 2. 적합도 검증(Goodness-of-Fit Test)은 이 데이터가 특정 이론적 분포와 일치하는지를 검증하는 방법이다. 3. 정규분포를 가정 시 정규성 검정을 가장 많이 활용하고 있다. 4. 정규분포를 가정하지 않을 시 카이제곱 검정을 이용해 적합도를 판단한다.	
68. 데이터 분할(Split)에 대한 설명으로 옳지 않은 것은? 1. 학습 데이터(훈련 데이터)보다 검증 데이터에서 성능이 좋은 하이퍼파라미터를 선정한다. 2. 테스트 데이터로 모델 간 성능을 비교한다. 3. 학습 데이터로 학습한다. 4. 데이터셋을 학습 데이터 검증 데이터, 테스트 데이터로 나누는 것이 적절하다.	학습 데이터보다 검증 데이터에서 성능이 좋은 하이퍼파라미터를 선정하는 것은 일반적이지 않다. (학습 데이터에서 검증 데이터보다 성능이 더 좋은 것이 보통이며, 과적합을 방지하는 것이 목적)
69. 다음 중 하이퍼파라미터 대한 설명으로 옳지 않은 것은? 1. 파라미터와 하이퍼파라미터는 학습 전에 결정다. 2. 하이퍼파라미터는 학습 과정 자체를 제어한다. 3. 하이퍼파라미터는 사람이 직접 입력값을 설정해줘야 한다. 4. 서로 다른 하이퍼파라미터값은 모델 학습과 정확도(Accuracy) 혹은 모델의 수렴율(Convergence Rate)에 영향을 미칠 수 있다.	파라미터(Parameter)는 학습 후 결정되지만, 하이퍼파라미터(Hyperparameter)는 학습 전에 설정해야 한다.
70. 하이퍼파라미터 최적화 기법에 대한 설명으로 옳지 않은 것은? 1. 수동탐색(Manual Search)은 사용자가 사전지식을 가지고 있다. 2. 무작위탐색(Random Search)는 다양한 조합들을 시험해 예상치 못한 결과를 얻을 수 있다. 3. 베이지안 최적화(Bayesian Optimization)는 새로운 하이퍼파라미터값에 대한 조사할 수행할 때에 사전지식 을 충분히 반영한다. 4. 그리드 분석기의 경험에 따라 값을 조절하는 게 최적이지만, 자동화를 위해 격자탐색(Grid Search) 등을 수행 한다.	베이지안 최적화는 사전지식을 반영하는 것이 아니라, 이전 실험 결과를 바탕으로 다음 하이퍼파라미터 값을 선택하는 방법입니다.
71. 다음 중 파라미터 최적화 기법이 아닌 것을 고르시오 1. RMSProp 2. AdaDelta 3. Nadam 4. Bayesian Optimization	*격자탐색(Grid Search) 등을 수행한다*는 자동화 기법이지만, ***경험에 따라 값을 조절하는 것이 최적***이라는 표현은 일반적으로 적용되지 않는다.
72. 랜덤포레스트 기법에 대한 설명으로 옳지 않은 것은? 1. 각각의 트리는 과적합 가능성이 있다. 2. 다수의 결정트리의 결과들 통해 최종결과를 도출한다. 3. 각각의 결정나무에 배깅과 같은 방법을 사용한다. 4. 전체 데이터셋으로 학습한다.	배깅(Bagging) 기법을 활용하여 여러 개의 결정트리를 학습하며, 전체 데이터셋을 하나의 트리에 학습하지 않는다.
73. 부스팅(Boosting)에 대한 설명으로 옳지 않은 것은? 1. 약학습기(Weak Learner)로 만든다. 2. 병렬로 학습한다. 3. 오답에 대한 가중값을 부여해 사용한다. 4. 보팅(Voting)과 함께 앙상블 학습유형으로 사용된다.	약한 학습기를 순차적으로 학습하는 방식으로 병렬 학습이 아니라 직렬 학습 방식이다.
74. 데이터에 대한 비즈니스 효과에 대한 설명으로 옳지 않은 것은? 1. 비즈니스 기여도는 데이터 분석결과를 활용하여 사업수행 혹은 과제수행 등을 통해 얻게 되는 긍정적인 영향 도를 의미한다. 2. 비즈니스 효과에 대한 정량적 가치 측정을 위해 각종 지표를 개발하였다. 3. 경영변화에 따라 비즈니스 효과 지표는 유연하게 변화한다. 4. 데이터의 가치(Value)는 부자요소, 속도와 규모는 비즈니스 효과를 나타낸다.	데이터의 속도와 규모는 비즈니스 효과가 아니라 빅데이터의 3V(Value, Velocity, Volume) 중 일부이다.
75. 시간시각화에 대한 설명으로 옳지 않은 것은? 1. 점그래프는 점의 집중도를 통해 표현하므로 시계열에 적합하지 않다. 2. 영역차트는 선그래프와 그래프 축사이의 면적으로 데이터를 표시한 그래프이다. 3. 막대그래프는 범주의 수가 7개 이하일 때 주로 사용한다. 4. 묶은선그래프는 점그래프를 선으로 이은 것이다.	
76. 다음 중 x축(가로축)과 y축(세로축) 각각에 두 변수의 순서쌍을 점으로 표현해 두 변수의 관계를 나타낸 그래프는?	