

3. ETL	ETL(Extract, Transform, Load)은 경형 데이터를 변환하고 적재하는 기술로, 반경형 데이터 수집보다는 경형 데이터 처리에 적합하다.
4. Crawling	
13. 데이터 변환에 대한 설명으로 옳은 것은?	데이터 변환(Data Transformation)은 데이터를 분석 가능한 형태로 변환하는 작업으로, 포맷 변경, 스케일링 등이 포함된다.
1. 데이터 유형을 변환하거나 데이터 분석이 용이한 형태로 변환하는 과정	결측값 변환, 이상값 제거는 데이터 정제 과정에 해당
2. 결측값 변환, 이상값 제거, 노이즈 데이터를 교정하는 과정	데이터 연계 및 통합은 데이터 통합(integration) 과정
3. 데이터 분석이 용이하도록 기존 또는 유사 데이터를 연계, 통합하는 과정	레거시 시스템 데이터 분석은 특정 시스템과 관련된 작업
4. 레거시 시스템(Legacy system)의 데이터와 함께 분석이 필요한 경우 수행	
14. 다음 중 데이터 비식별화 방법에 대한 설명으로 가장 적절하지 않은 것은?	데이터 마스킹은 비식별화 기법이 있지만, "적절적으로 식별할 수 있는 다른 값으로 대체"라는 표현이 옳지 않다. 마스킹은 원본을 특정 규칙에 따라 가리는 방식이므로, 암호화나 난수 대체 등과 구별된다.
1. 데이터 마스킹 : 개인식별이 가능한 데이터에 적절적으로 식별할 수 있는 다른 값으로 대체	특정 데이터를 식별하는 기법
2. 데이터 삭제 : 개인정보 식별이 가능한 특정 데이터를 삭제	데이터를 그룹으로 변환
3. 데이터 병주화 : 단일 식별 정보를 해당 그룹의 대표값으로 변환하거나 구간값으로 변환	개별 데이터를 집계하여 개인을 특정할 수 없게 하는 기법
4. 총계치라 : 개인정보에 대해 총계값을 적용해 특정 개인을 판단할 수 있도록 함	총계치라는 개인정보를 집계하여 특정 개인을 식별할 수 없도록 하는 방법이지만, 데이터 비식별화 방법으로는 적절하지 않습니다.
15. 비식별화 프라이버시 모델 중 특정한 추론이 안 된다고 해도 민감한 정보의 다양성을 높여 추론 가능성을 낮추는 기법은?	같은 그룹에 k명 이상 존재하도록 하는 기법
1. k-익명성	동일한 그룹 내에서 민감한 값이 일정 수준 이상 다양하도록 유지하는 방식으로, 특정 값의 빈도를 낮춰 개인의 정보 추론을 어렵게 만든다.
2. t-다양성	민감한 속성이 전체 데이터 분포와 유사하도록 조정
3. t-근접성	존재하지 않는 개념
4. k-민감성	
16. 다음을 설명하는 품질 특성을 고르시오.	
필수항목에 누락이 없어야 한다.	
예) 고객의 아이디는 NULL일 수 있다.	
1. 완전성	필수 데이터가 특정값이 존재하지를 의미한다.
2. 유일성	데이터가 중복되지 않도록 관리
3. 일관성	데이터 간 논리적인 일관성 유지
4. 신뢰성	데이터의 정확성과 안정성
17. 경형 데이터의 품질 기준에 대한 설명으로 가장 적절하지 않은 것은?	
1. 필수항목에는 누락이 없어야 하는 특성	완전성
2. 규정한 조건에서 사용될 때, 사용지에 의해 이해되고, 신뢰할 수 있게 하는 정도	해당 설명은 사용자 경험(UX)과 관련된 개념으로, 데이터 품질 기준과는 다소 거리가 있다.
3. 데이터 항목은 정해진 데이터 유효 범위 및 도메인을 충족해야 하는 특성	정확성
4. 데이터가 지켜야 할 구조, 값 등이 일관되게 정의되어야 하며 일치해야 하는 특성	일관성
18. 데이터 품질진단으로 도출할 수 있는 질문은 무엇인가?	
1. 왜 발생했는가?	원인 분석 과정
2. 언제 할 것인가?	실행 계획과 관련
3. 시간이 얼마날 것인가?	예측 분석
4. 어떻게 대응할 것인가?	문제 해결 단계
19. 전통적 분석 환경에서의 ETL에 대한 설명으로 알맞지 않은 것은?	
1. ETL은 Extract, Transform, Load 세 단어의 축약어로 데이터 소스시스템 및 환경으로부터 데이터를 추출하여 비즈니스 데이터로 변환 후 데이터 마트, 데이터 웨어하우스, ODS(Online Data Store)로 적재한다.	배치 ETL과 실시간 ETL 방식이 존재
2. ETL 구현을 위해 일괄 ETL(Batch ETL) 실시간 ETL(Real Time ETL)로 구분할 수 있다.	MPP 지원으로 대용량 데이터 처리 가능
3. 대용량 데이터 처리를 위해 MPP(작업 단계에서 다수의 프로세서가 동시 처리할 수 있게 하는 병렬처리 프로세스)를 지원한다.	ETL은 데이터를 추출하고 변환한 후 최종적으로 데이터 웨어하우스나 데이터 마트에 적재하는 과정이지, 중간 지장을 목적으로 하지 않는다.
4. ETL은 중간 단계에 저장하는 역할을 한다.	
20. 비정형 데이터 저장방식으로 알맞지 않은 것은?	
1. 단어, 문장	음성 데이터는 정적이지 않으며 시간에 따라 변화하는 시계열 데이터의 특성을 갖는다. 즉, 수학적 함수 형태(y=f(x))로 단순 표현하기 어렵다.
2. 음성 데이터는 정격이므로 y = f(x)의 형태	
3. 이미지는 RGB픽셀	
4. 동영상은 스트리밍 방식	
21. 이상값 탐지를 위한 상자그림(Boxplot)에서 측정 불가능한 항목은 무엇인가?	
1. 제1사분위수	상자그림(Boxplot)은 데이터의 사분위수(제1, 제3사분위수), 중앙값, 이상값 등을 나타내지만, 평균값(Mean)은 직접적으로 표시되지 않는다.
2. 사분위수 범위(IQR)	
3. 평균값	
4. 중앙값(Median)	
22. 레퍼 기법에 대한 설명으로 가장 부적절한 것은?	
1. 전진선택법은 변수를 알 수 없는 상태로 시작하여 반복할 때마다 가장 중요한 변수를 추가함으로써 더 이상 성능 향상이 없을 때까지 변수를 추가하는 방법이다.	변수 추가에 따라 모델이 변동할 수 있어 안정성이 낮다. 데이터에 따라 선택되는 변수가 달라질 수 있다.
2. 전진선택법은 변수값의 작은 변동에도 그 결과가 유지되어 안정성이 높다.	
3. 후진제거법은 모든 변수를 가지고 시작하고 가장 덜 중요한 변수를 하나씩 제거하면서 모델의 성능을 향상시키는 기법이다.	
4. 단계별 선택법은 전진과 후진제거법을 결합하여 사용하는 기법이다.	
23. 대표적인 차원축소 기법에 대한 다음의 설명 중 옳지 않은 것은?	
1. 주성분분석은 여러 변수들의 선형 결합으로 이루어진 주성분이라는 새로운 변수를 만들어 기존의 변수들을 요약하여 축소하며, 각 주성분 간에 우선순위가 없이 대응한다.	PCA의 주성분들은 중요도(분산 설명량)에 따라 순위가 정해진다. 1주성분이 가장 중요한 정보를 담고 있으며, 이후 주성분들은 중요도가 낮아진다.
2. 다차원회귀법은 데이터 속에 잠재해 있는 패턴, 구조를 찾아내어 소수 차원의 공간에 객체 간 근접성을 시각화하는 통계 기법으로 차원축소에 사용될 수 있다.	
3. 차원축소 기법 중 하나인 요인분석은 여러 개의 변수들로 이루어진 데이터에서 변수들 간의 상관관계를 고려하여 서로 유사한 변수들을 묶어 새로운 잠재요인을 추출해내는 분석방법이다.	
4. t-SNE는 데이터에서 지역 인접성을 보존하려고 시도하는 차원축소 알고리즘으로, 비선형적이며 비결정적이다.	
24. 아래의 설명 중 파생변수의 추가방법에 해당되는 것을 모두 고르시오.	
ㄱ. 한 값으로부터 특징들을 추출한다.	한 값에서 특정 추출(예: 날짜 --> 요일)
ㄴ. 한 레코드 내의 값들을 결합한다.	한 레코드 내 값 결합(예: 키, 몸무게 --> BMI)
ㄷ. 다른 데이터들의 부가적인 정보를 참조한다.	다른 데이터들 정보 참조(예: 고객 정보 + 거래 정보) 데이터 통합에 해당합니다.
ㄹ. 거래 레코드를 분리한다.	거래 레코드 분리 --> 데이터 정제 과정에 가까움, 데이터 분할에 해당
ㅁ. 복잡한 표현방식으로 변환한다.	복잡한 표현 변환 --> 데이터 인코딩 과정
1. ㄱ, ㄷ	
2. ㄴ, ㄹ	
3. ㄱ, ㄴ, ㄷ	
4. ㄱ, ㄴ, ㅁ	

15. 재현 자료(Synthetic data)에 대한 설명으로 옳은 것은? 1. 원본과 통계적으로 유사하나 가상으로 다시 만들어진 데이터이다. 2. 완전 재현 데이터는 민감한 정보에 대해서만 재현 데이터로 대체하는 방식이다. 3. 부분 재현 데이터는 정보 모두를 재현 데이터로 생성하는 방식이다. 4. 암호화 상태에서 데이터를 결합하고 연산/분석 등이 가능하다. 16. 다음 중 데이터 비식별화 방법에 대한 설명으로 가장 적절하지 않은 것은? 1. 데이터 마스킹 : 개인정보가 가능한 데이터에 직접적으로 식별할 수 없는 다른 값으로 대체 2. 데이터 삭제 : 개인정보 식별이 가능한 특정 데이터값을 삭제 3. 데이터 범주화 : 단일 식별 정보를 해당 그룹의 대표값으로 변환하거나 구간값으로 변환 4. 총계처리 : 개인정보에 대해 통계값을 적용해 특정 개인을 판단할 수 없도록 함 17. 다음 중 민감정보가 아닌 것을 고르시오. 1. 종교 2. 신용등급 3. 정치성향 4. 인종정보 18. 전통적 분석 환경에서의 ETL에 대한 설명으로 알맞지 않은 것은? 1. ETL은 Extract, Transform, Load 세 단어의 축약어로 데이터 소스시스템 및 환경으로부터 데이터를 추출하여 비즈니스 데이터로 변환 후 데이터 마트, 데이터 웨어하우스, ODS로 적재한다. 2. ETL 구현을 위해 일괄 ETL(Batch ETL) 실시간 ETL(Real Time ETL)로 구분할 수 있다. 3. 대용량 데이터 처리를 위해 MPP(작업 단계에서 다수의 프로세서가 동시 처리할 수 있게 하는 병렬처리 프로세스)를 지원한다. 4. ETL은 중간 단계에 저장하는 역할을 한다. 19. 데이터 웨어하우스(DW)의 특징으로 옳지 않은 것은? 1. 주제 중심 2. 통합 구조 3. 시계열성 4. 휘발성 20. NoSQL의 유형별 종류로 옳게 짝지어진 것을 고르시오. 1. Document-oriented: Oracle Berkeley DB, Voldmorte 2. Key-Value: Redis, HyperTable 3. Column-Oriented: Cassandra, Google BigTable 4. Graph: Neo4j, HBase 21. 데이터 정제에 대한 설명으로 옳지 않은 것을 고르시오. 1. 정제는 데이터 전처리의 한 과정이다. 2. 결측값을 채우고 이상값을 삭제하거나 대체한다. 3. 데이터의 누락값, 불일치, 오류의 수정 및 숫자나 날짜등의 형식에 대해 일관성 유지를 수행하게 된다. 4. 데이터 정제는 1회성으로 완료된다. 22. PCA(주성분분석) 기법에 대한 설명으로 옳은 것은? 1. 데이터 처리 기법이다. 2. 다수 변수들을 변수들 간의 상관관계를 분석하여 공통 자원들을 통해 축약한다. 3. 비유사성을 측정하여 2차원 또는 3차원 공간상에 점으로 표현한다. 4. 상관행렬과 공분산행렬을 이용한다. 23. 다음 중 요인분석(Factor Analysis)에 해당되는 것을 모두 고르시오. 가. 데이터에 관찰할 수 있는 잠재적 변수가 존재한다고 가정한다. 나. 다수 변수들을 변수 간의 상관관계를 분석하고 공통 자원으로 축약하는 통계 기법이다. 다. 상관계수 ±3을 벗어나는 자료는 부적합하다. 라. 사회과학, 설문조사 등에 많이 활용되는 기법이다. 1. 가 2. 가, 나 3. 가, 다, 라 4. 가, 나, 다, 라 24. Box-Cox 변환에 대한 설명으로 옳지 않은 것을 고르시오. 1. 변수 변환기법이다. 2. 로그변환을 이용한다. 3. 자원축소 기법이다. 4. 거듭곱변환을 이용한다. 25. 변수 변환기법 중 스케일링 기법이 아닌 것은? 1. 범주화 2. 최소최대 정규화 3. 표준화 4. 최대-절대값 정규화 26. 불균형 데이터에 대한 설명으로 옳지 않은 것은? 1. 불균형 데이터가 존재할 경우 많은 비율을 가진 집단의 정확도(Accuracy)가 높아지므로 모형의 성능 판별이 어려워지게 된다. 2. 작은 비율을 가진 집단의 재현율(Recall)은 작아지는 현상이 발생할 수 있다. 3. 변수가 가진 데이터에서 각 집단에 속하는 데이터의 수가 동일하지 않은 상태이다. 4. 기존 변수에 특정 조건 혹은 함수 등을 활용하여 만들거나 기존 변수들을 조합하여 새롭게 만들어진 과정이다. 27. 상관관계 분석에 대한 설명으로 가장 부적절한 것은? 1. 두 개의 변수 간의 직선관계의 선형성과 산포도로 확인할 수 있다. 2. 양(+)의 상관관계는 두 변수가 동반 증가하는 것이며, 음(-)의 상관관계는 두 변수의 값이 반대로 증감하는 것이다. 3. -1 ~ +1 사이의 값으로 -1과 +1은 완전한 비선형관계를 의미한다. 4. 두 변수의 선형관계 측정을 위한 수치로 공분산 상관계수를 사용한다.	데이터 마스킹은 직접 식별이 불가능하도록 변환하는 기법이지만, 특정 값으로 대체하는 것만을 의미하지는 않습니다. 데이터 범주화는 단일 식별 정보를 그룹의 대표값으로 변환하는 것이 아니라, 구간값으로 변환하는 것을 의미합니다. 따라서 이 설명은 적절하지 않습니다. ETL은 데이터를 추출, 변환, 적재하는 과정이며, 단순 저장하는 역할이 아닙니다. 데이터 웨어하우스(DW)는 휘발성이 아니라, 지속적인 데이터 저장과 분석을 위한 비휘발성 시스템입니다. Document-Oriented: MongoDB, CouchDB Key-Value: Redis, Riak Graph: Neo4j, ArangoDB 데이터 정제는 지속적인 과정이며, 데이터가 추가되거나 업데이트될 때마다 반복적으로 수행해야 한다. PCA는 변수 간의 상관관계를 분석하여 차원을 축소하는 기법이다. 2차원 또는 3차원 공간에 표현하는 것은 다차원 척도법(MDS)과 관련 있다. 상관행렬과 공분산행렬을 이용하는 것은 맞지만, 이는 PCA의 일부 과정이지 PCA의 본질적인 설명은 아니다. 요인분석은 관찰할 수 없는 잠재 변수를 가정하며, 다수의 변수를 상관관계를 기반으로 축소하는 통계 기법이다. 상관계수 ±3을 벗어나는 자료는 부적합하다는 내용은 틀렸다(상관계수는 -1~1 사이의 값). 사회과학, 설문조사 등에 많이 활용되지만, 이 자체가 요인분석의 필수 요소는 아니다. Box-Cox 변환은 자원 축소 기법이 아니라 데이터 변환(정규화) 기법이다. 범주화는 데이터를 그룹으로 나누는 과정이며, 스케일링(정규화, 표준화 등)과는 다르다. 4번은 새로운 변수를 만드는 방법으로, 불균형 데이터 자체의 개념과는 다르다. -1과 +1은 완전한 선형관계를 의미하며, 비선형 관계를 의미하지 않는다.
--	--

라. 바둑에서 인간의 데이터를 사용하지 않고, 규칙만으로 보상을 통한 학습 사용	알파고는 인간 데이터를 사용하지 않고, 보상 기반으로 학습하는 강화학습을 사용함.
1. RNN, CNN, RNN&CNN, 강화학습	
2. CNN, RNN, RNN&CNN, 강화학습	
3. 강화학습, CNN, RNN, RNN&CNN	
4. RNN, 강화학습, RNN&CNN, CNN	
42. 다음 중 파라미터 선택에 대한 내용이 아닌 것은?	
1. 사람의 수작업으로 측정되고 결정됨	
2. 모델 내부에서 확인이 가능한 변수로 데이터를 통해 산출 가능한 값	
3. 예측을 수행할 때 모델에 의해 요구되어지는 값	
4. 측정되거나 데이터로부터 학습됨	
43. 아래 설명의 문제에 대한 해결 기법으로 가장 알맞지 않은 것은?	
회귀분석에서 독립변수를 강해 강한 상관관계가 나타나는 문제이다. 이러한 문제가 존재하면 경쾌한 회귀계수의 추정이 어렵다.	
1. 상관관계가 높은 독립변수 중 하나 혹은 일부를 제거한다.	
2. 변수를 변형시키면 안 되고, 기존 관측치를 그대로 이용한다.	
3. 자료를 수집하는 현장의 상황을 보아 상관관계의 이유를 파악하여 해결한다.	
4. 주성분분석을 이용한 대각행렬의 형태로 공선성을 없애 준다.	
44. 다중회귀모형(모형)의 통계적 유의성 확인 방법은 무엇인가?	
1. F통계량을 확인한다	
2. t검정을 실시한다	
3. ANOVA를 수행한다.	
4. 교차검증을 실시한다.	
45. 외삽결정나무의 회귀트리(Regression Tree) 모형(모형)을 만들 때의 분류 기준은 무엇인가?	
1. t통계량	
2. 분산감소량, F통계량	
3. 엔트로피지수	
4. 지니지수, 카이제곱통계량	
46. 다음 중 활성화 함수의 설명으로 적절한 것?	
1 로지스틱회기 모델에서의 회귀계수와 유사하게 해석한다.	
2 L2 penalty를 사용한다.	
3 선형이면 의미가 없다.	
4. 시그모이드 함수가 대표적이다.	
47. 활성화 함수 중 시그모이드와 하이퍼볼릭탄젠트(Tanh) 함수의 결과값을 순서대로 도출하시오.	
1. 0 ≤ y ≤ 1, -1 ≤ y ≤ 1	
2. -1 ≤ y ≤ 1, -1 ≤ y ≤ 1	
3. -1 ≤ y ≤ 0, -1 ≤ y ≤ 0	
4. -1 ≤ y ≤ 1, 0 ≤ y ≤ 1	
49. 서포트벡터머신(SVM)의 설명으로 틀린 것은?	
1. 분류와 회귀분석에 사용되는 지도학습 알고리즘이다.	
2. 데이터가 사상의 공간에서 경계선과 가장 근접한 데이터를 서포트벡터라고 부른다.	
3. 테스트가 매우 쉽다.	
4. 고차원에서의 비정 추측이 어려운 경우 자원의 지주를 회피한다.	
50. 다음 중 서포트벡터머신(SVM)의 커널 종류가 아닌 것은?	
1. 다항식 커널	
2. 회귀형 커널	
3. 가우시안 커널	
4. 시그모이드 커널	
51. 연관규칙의 "A→B"의 향상도는?	
지지도 : 3/10, P(A): 6/10, P(B): 6/10.	
1. 63%	
2. 36%	
3. 38%	
4. 83%	
52. 주성분분석(PCA)의 공분산행렬에 대한 설명으로 옳지 않은 것은?	
1. 공분산행렬의 고유벡터는 데이터가 어떤 방향으로 분산되었는지를 나타낸다.	
2. 변수들 사이의 공분산 행렬로 나타낸 값이다.	
3. 경방행렬은 불가능하다.	
4. 전치를 시켰을 때 동일한 행렬이 나타나는 대칭행렬이다.	
53. 다음을 참고하여 데이터에 대한 주성분분석(PCA)의 결과를 해석으로 옳은 것은?	
Importance of components: PC1 PC2 PC3 PC4 Standard deviation 30.1227 27.0528 9.07614 6.15239 Proportion of Variance 0.5157 0.4159 0.04682 0.02151 Cumulative Proportion 0.5157 0.9317 0.97849 1.00000	
1. 두 번째 주성분의 누적기여율은 93.17%이다.	
2. 최소 70%의 분산 설명력을 갖기 위한 주성분의 개수는 3개이다.	
3. 누적기여율은 세 번째 주성분의 값으로 고정되어 있다.	
4. 첫 번째 주성분으로 기준을 상을 수 있다.	
54. 다음 시계열의 요인 중 틀린 것은?	

알파고는 인간 데이터를 사용하지 않고, 보상 기반으로 학습하는 강화학습을 사용함.

파라미터는 모델 내부에서 데이터를 통해 학습되거나 측정되는 값입니다. 사람이 수작업으로 결정하는 것은 하이퍼파라미터입니다. 파라미터는 사람이 설정하는 값으로, 모델이 학습을 통해 결정하는 것은 가중치나 편향과 같은 하이퍼파라미터임.

모델 내부에서 확인 가능한 변수로 데이터를 통해 산출 가능한 값은 파라미터입니다.

상관관계가 높은 독립변수 중 하나 혹은 일부를 제거하는 것은 다중공선성 문제 해결에 적합합니다. 다중공선성이 존재하면 변수 변형(표준화, 주성분 분석 등)이나 제거가 필요함. 자료를 수집하는 현장의 상황을 보아 상관관계의 이유를 파악하여 해결하는 것도 적절한 방법입니다. 주성분분석을 이용한 대각행렬의 형태로 공선성을 없애는 것도 적절한 방법입니다.

F통계량은 모델 전체의 유의성 검정에 사용됨. t검정은 개별 변수의 유의성을 평가함. ANOVA는 집단 간 평균 차이를 검정하는 방법. 교차검증은 모델 일반화 성능을 평가하는 데 사용됨.

회귀트리는 연속형 값을 예측하며, 분산 감소량을 기준으로 최적 분할을 결정함. F통계량은 회귀분석에서 개별 계수의 유의성을 확인하는 데 사용됩니다. 회귀트리는 분산을 최소화하는 방향으로 분할합니다. 따라서 분산감소량이 주요 기준입니다. 3번(엔트로피), 4번(지니지수, 카이제곱)은 분류트리에 사용됨.

활성화 함수의 대표적인 예로 시그모이드, ReLU, Tanh 등이 있음. 로지스틱 회귀 계수와 동일함 L2 페널티는 정규화 기법 활성화 함수가 선형이면 신경망의 층을 깊게 하는 의미가 없어집니다. 활성화 함수는 신경망에서 비선형성을 추가하는 데 사용됩니다. 시그모이드 함수는 대표적인 활성화 함수 중 하나입니다.

시그모이드: 0에서 1 사이의 값 출력 / Tanh: -1에서 1 사이의 값 출력

SVM은 테스트가 쉽지 않으며, 특히 고차원 데이터에서 계산 비용이 높을 수 있습니다. SVM은 커널 트릭을 이용해 고차원 특징 공간에서 효과적으로 분류 가능하지만, 차원의 저주 자체를 해결하는 방법은 아님.

*회귀형 커널*이라는 개념은 없음.

$$\text{향상도} = \frac{\text{지지도}(A \rightarrow B)}{P(A) \times P(B)}$$
$$= \frac{3/10}{(6/10) \times (6/10)} = \frac{0.3}{0.36} = 0.8333$$

향상도(Lift)는 P(B|A) / P(B)로 계산됩니다. 여기서 P(B|A) = 지지도 / P(A) = (3/10) / (6/10) = 0.5, P(B) = 6/10 = 0.6. 따라서 향상도 = 0.5 / 0.6 = 0.83 (83%).

공분산 행렬은 항상 정방행렬이므로, 이 설명이 틀림

누적 기여율이 PC2에서 **0.9317(93.17%)**이므로 정답. 누적기여율을 보면, PC1과 PC2가 93.17%의 분산을 설명합니다. 따라서 최소 70%의 분산 설명력을 갖기 위한 주성분의 개수는 2개입니다.

	3. 학습 단계에서의 과적합(Over Fitting) 문제 해결 4. 데이터의 오차에 대한 교정용 수형 70. 다음 가설 검증 설정 중 틀린 것은? 1. P값(P-value)이 유의수준보다 클 때, 귀무가설을 기각한다. 2. 대립가설이 방향성을 갖는 경우를 단측검정이라 한다. 3. 모수는 모집단 분포 특성을 규정짓는 척도이며, 표본을 이용하여 이 모수에 대해 유의성을 검증한다. 4. 기각역이란 P값(P-value)이 유의수준보다 같거나 작아지게 하는 검정통계량값의 영역이다. 71. 다음 중 검정도 검정과 관련 없는 지표는? 1. y-결편 2. P값(P-Value) 3. F통계량 4. 잔차 히스토그램 72. 인공지능망 과적합을 막기 위한 걸로 옳지 않은 것은? 1. 설명변수의 수를 늘린다. 2. 학습률 줄이기 3. 가중치 조정 4. 은닉층 줄이기 73. 파라미터 최적화 기법 중 아래 설명 기법은? 파라미터의 기울기를 구해 기울어진 방향으로 파라미터값을 갱신하는 일을 반복해 최적의 값을 추출하는 기법이다. 급격한 번곡경의 한계를 보인다. 1. 확률적 경사하강법 (Stochastic Gradient Descent, SGD) 2. 모멘텀(Momentum) 3. 아디그라드(Adagrad) 4. 아담(Adam) 74. 다음 중 아래 설명으로 맞는 방법론은? 한 학습기를 여러 개 연결하여 강한 학습기를 만드는 앙상블 방법이다. 오분류 데이터들에 높은 가중치를 부여하여 새로운 분류 규칙을 만들고 반복해 최종 모델을 만드는 알고리즘이다. 1. 배깅(Bagging) 2. 부스팅(Boosting) 3. 랜덤포레스트(Random Forests) 4. 스택킹 (Stacked Generalization) 75. 다음중 시각화 기법이 아닌 것은? 1. 산점도 2. 박스플롯 3. 히스토그램 4. 원핫인코딩 76. 시각화에 대한 성과지표 설명으로 가장 옳지 않은 것은? 1. 데이터 시각화는 데이터 분석결과를 쉽게 이해할 수 있도록 시각적으로 표현하고 전달되는 과정이다. 2. 비즈니스에 기여도 평가의 영향력 가치를 측정할 수 있다. 3. 데이터 시각화를 위해 새로운 지표를 생성하지 않아도 된다. 4. 비즈니스 의사결정에 사용할 수 있다. 79. 다음은 어떤 시각화 기법에 대한 설명인가? 다변량 데이터 사이에 존재하는 변수 사이의 연관성, 분포와 패턴을 찾을. 집단 간의 상관관계를 확인 수치의 변화 예측 1. 시간시각화 2. 관계시각화 3. 비교시각화 4. 공간시각화 80. 다음 중 분석결과를 활용한 데이터 시각화를 통해 얻을 수 있는 대표적인 기능이 아닌 것은? 1. 커뮤니케이션 2. 인사이트 발굴 3. 연동 모델 선정 4. 디스커버리		교차검증은 모델의 일반화 성능을 평가하는 데 사용되며, 데이터 오차 교정이 주된 목적이 아닙니다. P값이 유의수준보다 크면 귀무가설을 기각하지 않습니다. y결편은 회귀 분석에서 사용되며, 적합도 검정(F-검정, P-Value, 잔차 히스토그램 등)과는 관련이 없습니다. 설명변수를 늘리면 오히려 과적합이 발생할 가능성이 커집니다. SGD는 기울기를 구해 최적화를 진행하는 알고리즘으로, 번곡점 문제를 가질 수 있습니다. 모멘텀(Momentum)은 SGD에 관성을 추가한 기법입니다. 아디그라드(Adagrad)는 학습률을 조정하는 기법입니다. 아담(Adam)은 모멘텀과 아디그라드를 결합한 기법입니다. 부트스트랩 샘플을 사용하여 여러 모델을 만드는 방법입니다. 부스팅은 오분류된 데이터에 높은 가중치를 부여하여 학습을 반복하는 방식입니다. 배깅의 확장으로, 의사결정나무를 사용합니다. 여러 모델의 예측 결과를 결합하는 방법입니다. 원핫인코딩은 범주형 데이터를 수치형으로 변환하는 기법이치 시각화 기법이 아닙니다. 시각화는 정량적 가치를 측정하는 것이 아니라, 데이터를 시각적으로 표현하여 이해를 돕는 데 목적이 있습니다. 시각화를 위해서는 새로운 지표를 생성해야 할 수도 있습니다. 다변량 데이터 간의 관계를 분석하는 것은 관계 시각화에 해당합니다. 다변량 데이터 사이에 존재하는 변수 사이의 연관성, 분포와 패턴을 찾고, 집단 간의 상관관계를 확인하며, 수치의 변화를 예측하는 데 사용됩니다. 데이터 시각화는 연동 모델 선정과 직접적인 관련이 없습니다. 연동 모델 선정은 데이터 시각화를 통해 얻을 수 있는 기능이 아닙니다. 데이터 시각화는 주로 커뮤니케이션, 인사이트 발굴, 디스커버리에 사용됩니다.
4월	01. 가트너가 3V로 정의한 빅데이터의 특징이 아닌 것은? 1. 가치(Value) 2. 크기(Volume) 3. 속도(Velocity) 4. 다양성(Variety) 02. 1 제타바이트에 1byte의 아스키 코드를 얼마만큼 넣을 수 있는가? 1. 2의 40승 2. 2의 50승 3. 2의 60승 4. 2의 70승 03. 공공데이터에서 제공하는 파일의 형식이 아닌 것은? 1. XML 2. SQL 3. JSON 4. CSV		제타바이트(ZB)는 2^70바이트

2. 특이도가 1일 때 정확도는 1/2이다.	
3. 민감도가 1/2일 때 정확도는 1/2이다.	
4. 민감도와 특이도가 같을 때 정확도도 특이도와 같다.	
64. 혼동행렬에서의 FN 해석에 대한 것으로 알맞은 것은?	
1. 예측값 False, 실제값 False	
2. 예측값 False, 실제값 True	
3. 예측값 True, 실제값 False	
4. 예측값 True, 실제값 True	
65. 데이터 불균형이 있을 경우 사용하는 평가지표로 옳지 않은 것은?	
1. 민감도	
2. 정확도	
3. 오분류율	
4. ROC곡선	
66. 홀드아웃 관련 데이터가 아닌 것은?	
1. 총괄 데이터	
2. 학습 데이터	
3. 검증 데이터	
4. 테스트 데이터	
67. 케이폴드 교차검증(K-fold CV)에 대한 설명 중 옳지 않은 것은?	
1. 학습 데이터(훈련 데이터)와 검증 데이터 혹은 테스트 데이터로 분할	
2. k = 3 이상만 가능	
3. k개의 균일한 서브셋	
4. k - 1개의 부분집합을 학습 데이터로 사용	
69. 다음 관측값에 대한 설명으로 옳지 않은 것은?	
54, 46, 60, 40	
1. 기대빈도 50	
2. 도비율 P(54)는 1/4	
3. 카이제곱값 4.64	
4. 카이제곱(3) = 7.8이라면, 귀무가설을 기각한다.	
71. 정준연결 (Canonical link)의 로그 함수로 알맞은 것은?	
1. 정규분포	
2. 베르누이분포	
3. 포아송분포	
4. 감마분포	
72. 포아송분포에 대한 적합도 검정을 한다. 보기 중 옳지 않은 것은?	
1. 하루에 일어난 사건에 대한 평균을 구해야 한다.	
2. 카이제곱값이 클수록 귀무가설을 기각한다	
3. 란다는 어떤 일정 시간과 공간의 구간 안에서 발생한 평균 시간 수를 의미하지 않는다.	
4. P값이 유의수준보다 작으면 귀무가설을 기각한다.	
73. 과대적합될 때 대응방법으로 옳지 않은 것은?	
1. 정규화(Regularization)	
2. 배치정규화(Batch Regulation)	
3. 드롭아웃(Drop-Out)	
4. 맥스풀링(Max Pooling)	
74. 다음 중 시공간시각화 기법으로 가장 알맞은 것은?	
1. 히스토그램	
2. 체르노프페이스	
3. 지도열화	
4. 평행표표계	
75. 보고서 작성시 적절한 방법으로 가장 거리가 먼 것은?	
1. 전문용어를 많이 사용한다.	
2. 쉽게 이해할 수 있도록 작성한다.	
3. 비즈니스에 사용할 수 있도록 한다.	
4. 보고서를 통해 성과기준과 기여도를 표현할 수 있도록 한다.	
76. 비교그래프가 아닌 것은?	
1. 막대그래프	
2. 레이더차트	
3. 히트맵	
4. 산점도	
77. 뉴럴네트웍스에 대한 설명으로 가장 거리가 먼 것은?	
1. 발주형과 수지형 모두의 분포를 알 수 있다.	
2. 히스토그램의 y축을 평균으로도 나타낼 수 있다.	
3. 뉴럴네트웍스는 뉴럴활동일도함수와 반비례적인 형태를 보인다.	
4. 계급수를 잘 정해야 정확한 분포 파악이 가능하다.	
79. 효과제인 인포그래픽의 조건 중 가장 적절하지 않은 것은?	
1. 인포메이션(Information)과 시각적 그래프의 합성어이다.	
2. 최대한 많은 정보를 담는다.	
3. 쉽게 이해할 수 있도록 그래픽과 텍스트를 조합해 사용한다.	
4. 실용적 메시지 전달을 위해 차트, 다이어그램, 일러스트레이션 등을 사용한다.	
민감도 0, 특이도 1은 모든 양성을 음성으로 예측하는 경우입니다.	
ROC 그래프에서 특이도는 감소하며, FPR(1 - 특이도)이 증가하는 방향으로 그려집니다.	
ROC 곡선에서 가장 이상적인 상태는 민감도(Sensitivity)가 1이고, 특이도(Specificity)도 1인 경우입니다. 이는 완벽한 분류기를 의미합니다	
데이터가 불균형할 경우, 단순한 정확도(Accuracy)는 신뢰할 수 없습니다. 예를 들어, 99%가 한 클래스일 때 무조건 그 클래스로 예측해도 높은 정확도를 가질 수 있기 때문입니다.	
홀드아웃 방법에서는 데이터를 학습(Train), 검증(Validation), 테스트(Test) 데이터로 나누어 사용합니다.	
K-fold 교차검증에서 K=2도 가능합니다.	
주어진 데이터에서 카이제곱값을 직접 계산해야 하는데, 4.64가 맞지 않을 가능성이 큼니다.	
포아송분포의 정준연결 함수는 로그 함수입니다.	
란다(λ)는 포아송분포에서 일정한 시간/공간에서 발생하는 사건의 평균 개수를 의미합니다.	
맥스풀링은 CNN에서 사용하는 기법이며, 과대적합을 직접 해결하는 기법은 아닙니다.	
시공간 데이터를 효과적으로 시각화하는 방법으로 지도 기반 시각화가 가장 적절합니다.	
산점도는 두 변수 간의 관계를 나타내는 그래프입니다.	
히스토그램은 연속형 데이터에 사용됩니다.	
뉴럴네트웍스는 뉴럴활동일도함수와 비례적인 형태를 보이며, 반비례적인 형태를 보이지는 않습니다.	
너무 많은 정보는 가독성을 해칩니다.	

4. 네트워크 데이터 베이스	
20. 다음 중 비경형 데이터에 관한 설명으로 틀린 것은?	
1. 데이터 스키마를 지원한다.	
2. 주로 DB to DB를 사용해 수집한다.	
3. Nosql을 사용한다	
4. 데이터 레이크보다 데이터 웨어하우스를 사용한다.	
21. 데이터 처리 기법에 대한 설명 중 옳지 않은 것은?	
1. 데이터 정제 : 결측값, 노이즈, 이상값 등 데이터 오류 요인을 제거한다.	
2. 데이터 통합: 정제된 다수의 데이터를 통합한다.	
3. 데이터 축소: 노이즈 제거 위해 정규화한다.	
4. 데이터 변환: 정규화 등으로 분석이 편하도록 한다.	
22. 데이터 정제에 대한 설명으로 옳지 않은 것은?	
1. 데이터를 사용하기 쉽게 변환	
2. 결측값 대체	
3. 이상값 제거	
4. 노이즈 교정	
23. 결측값 처리방법에 대한 설명으로 적절하지 않은 것은?	
1. 관전사제법: 결측값 부분만 없애지 않고, 결측값이 있는 데이터 전체를 삭제한다.	
2. 평균대치법: 관측된 값의 평균값으로 대체한다.	
3. 회귀대치법: 회귀식의 예측값으로 결측값을 대체한다.	
4. 다중대치법: 통계적인 방법을 이용한다.	
24. 이상값 처리에 대한 설명으로 틀린 것은?	
1. 이상값은 반도에 비해 영향력이 작으므로 분석에서는 무시한다.	
2. 삭제 시 데이터가 적아지 분산은 커지고, 편향이 발생할 확률은 높아진다.	
3. 결측값 처리에서 사용하는 단순대치법과 다중대치법은 사용할 수 없다.	
4. 평균값 대체도 결측값 대체와 같이 신뢰성이 저하되지 않는다.	
25. 데이터 이상값 발생 원인으로 옳지 않은 것은?	
1. 측정오류	
2. 처리오류	
3. 표본오류	
4. 보고오류	
26. 회귀전단 시 이상값 및 영향값 탐색 방법으로 틀린 것은?	
1. 라쏘회귀	
2. AIC(Akaike Information Criterion)	
3. 사분위수 범위	
4. 레버리지(Leverage)	
28. 다음 중 연속형 변수가 아닌 것은?	
1. 키	
2. 실내온도	
3. 성인의 혈액형	
4. 책 두께	
29. 파생변수에 대한 설명으로 옳지 않은 것은?	
1. 기존 변수에 특정 조건이나 함수를 활용하기도 한다.	
2. 유의미한 특성이 객관적으로 반영되어야 한다.	
3. 결측값으로 주변 값을 채우기도 한다.	
4. 다수 필드 내에 시간 중속적인 데이터를 피해서 사용하는 방법도 있다.	
30. 최소-최대 정규화 시 세 학생의 성격(60, 70, 80) 합은?	
1. 0.5	
2. 1.0	
3. 1.5	
4. 2.0	
31. 다음 중 독립변수 12개와 종변 1개를 포함하는 모델이 있다. 변수 1개당 범주 3개씩 가질다면 회귀모수 개수는?	
1. 24개	
2. 25개	
3. 36개	
4. 37개	
32. 클래스 불균형(Class Imbalance)에 대한 설명으로 옳지 않은 것은?	
1. 이상값 대체는 결측값을 처리할 경우와 같은 신뢰도 문제를 발생시키지 않는다.	
2. 무게 균형(Weight Balancing)으로는 해결 불가능하다.	
3. 언더샘플링 혹은 오버샘플링으로 해결할 수 있다.	
4. 클래스의 개수와는 무관하다.	
33. 다음 중 인과관계분석(Causal Analysis)에 대한 설명으로 틀린 것은?	
1. 변수 간의 상관성을 확인한다.	
2. 해석을 포함하고 있지 않다.	
3. 이상값 파악이 용이하다.	
4. 독립변수와 종속변수 간의 인과관계를 분석한 것이다.	
차원 축소 기법(PCA, 요인 분석)이나 샘플링을 통해 데이터 크기를 줄이는 과정이지, 노이즈 제거와는 직접적인 관련이 없다. 노이즈 제거는 데이터 정제의 영역이다.	
데이터 정제는 데이터를 "변환"하는 과정이 아니다. 변환은 데이터 변환(Transformation) 단계에서 수행된다. 데이터 정제는 결측값을 처리하고 이상값을 제거하는 과정이다.	
데이터의 일부만 삭제하는 것이 아니라, 결측값이 하나라도 포함된 행(row) 전체를 삭제하는 방법이다. 데이터 손실이 크기 때문에 신중하게 사용해야 한다.	
이상값을 무조건 무시하면 데이터 분석의 신뢰도가 낮아질 수 있다. 이상값이 중요한 정보일 수도 있기 때문이다. 삭제 시 데이터가 적아지 분산은 커지고, 편향이 발생할 확률은 높아진다. 단순대치법과 다중대치법은 결측값 처리 방법으로, 이상값 처리에는 일반적으로 사용되지 않는다. 평균값 대체 시 데이터의 실제 분포를 왜곡할 수 있으므로 신뢰성이 저하될 수 있다.	
이상값을 평균값으로 대체하는 것은 신뢰성이 저하될 수 있습니다. 이상값은 데이터의 분포를 왜곡할 수 있으므로, 평균값 대체는 적절하지 않을 수 있습니다.	
센서 오작동, 기기 결함 등으로 인해 발생하는 오류. 데이터 변환, 저장 과정에서 발생하는 오류. 샘플이 모집단을 제대로 대표하지 못할 때 발생하는 오류. 표본오류는 이상값 발생 원인이 아니라, 표본 추출 과정에서 발생하는 오류입니다. 일반적으로 이상값 발생 원인이라기보다는 데이터 입력 오류(입력 실수)와 관련이 있다.	
변수 선택을 수행하는 기법이며, 이상값 탐색과 직접적인 관련이 없다. 모델 선택을 위한 지표이며, 이상값 탐색과는 관계없다. 데이터의 이상치를 탐색하는 방법이지만, 회귀전단과는 관련이 적다. 회귀 분석에서 데이터 포인트가 회귀선에 미치는 영향을 측정하는 지표로, 이상값 탐색에 활용된다.	
파생변수는 기존 변수에서 새로운 변수를 생성하는 과정이지, 결측값을 채우는 과정이 아니다. 결측값 처리와는 별개 개념이다.	
각 독립변수는 범주가 3개이므로, 각 변수당 2개의 더미 변수가 필요합니다. 따라서 12개 변수에 대해 24개의 더미 변수가 필요하며, 종변 1개를 포함하면 총 25개의 회귀모수가 필요합니다. 독립변수 12개 × 각 변수의 범주 수 3개 = 36개 (공변 포함 X)	
Weight Balancing은 클래스 불균형을 해결하는 데 사용할 수 있다.	
클래스 불균형은 클래스의 개수와 직접적으로 관련이 있습니다. 특정 클래스의 샘플 수가 다른 클래스에 비해 현저히 적을 때 발생합니다.	

35. 산도계수란 대한 설명으로 옳지 않은 것은? 1. 사분위수 범위는 제3분위에서 제1분위수 값 부분까지다. 2. 왜도는 분포의 기울어진 정도를 설명한 통계량이다. 3. 왜도는 그래프 양쪽의 뒤틀림 정도를 뜻한다. 4. 변동계수의 값이 작으면 상대적인 차이가 작고, 클수록 상대적인 차이가 크다는 것을 의미한다.	49. 다음 수식에 대한 설명으로 옳은 것은? 49. 다음 수식에 대한 설명으로 옳은 것은? $\ln\left(\frac{P(Y=1 X)}{1-P(Y=1 X)}\right) = \beta_0 + \beta_1 X$ 1. X가 1단위 증가하면 오즈 값을 증가한다. 2. X가 1단위 증가하면 b 만큼 증가한다. 3. X가 1단위 증가하면 y만큼 증가한다. 4. X가 1단위 증가하면 e^y만큼 증가한다.	청도(Kurtosis)는 그래프의 중심이 얼마나 뾰족한지를 뜻하며, 양쪽의 뒤틀림 정도와는 관계없다. 사분위수(Q1, Q2, Q3)는 개별적인 값이며, 사분위수 범위(IQR)는 Q3 - Q1이다. 정규분포에서 왜도(Skewness)는 0, 청도(Kurtosis)는 3이 기본값이다. 표본집단을 통해 모집단을 추론하는 것이 올바른 방향이다. 머신러닝 모델은 통계분석과 마찬가지로 결과물에 대한 공식을 도출할 수 있습니다. 특히 선형회귀나 로지스틱 회귀와 같은 모델은 명시적인 공식을 가지고 있습니다. 머신러닝도 결과물에 대한 수학적 모델(공식)을 도출할 수 있다. 예를 들어 선형회귀(Linear Regression)는 통계적 방법이지만 머신러닝 모델이다. 오차항(Residual)은 종속변수와 독립적이어야 한다. 즉, 선형관계가 아니라 무작위 분포(Random Distribution)여야 한다. 선형회귀분석에서 오차항은 종속변수와 선형관계가 없어야 합니다. 오차항은 독립적이며, 종속변수와 선형관계는 독립변수와 종속변수 사이에만 존재합니다. 교호작용(Interaction Effect)이 발생하면 회귀식에 추가 항(term)이 포함되어 변할 수 생긴다. 교호작용이 발생하면 회귀식에 변화가 생깁니다. 교호작용은 독립변수 간의 상호작용을 의미하며, 이는 회귀식에 추가적인 항을 포함시켜 줍니다. 독립변수가 들어들면 결정계수는 일반적으로 작아진다. 다만, 조정된 결정계수(Adjusted R²)는 변수가 적절하게 제거되면 올라갈 수도 있음. 독립변수가 적어지면 결정계수는 일반적으로 작아집니다. 결정계수는 독립변수가 종속변수를 얼마나 잘 설명하는지를 나타내는 지표로, 독립변수가 많을수록 결정계수가 커질 수 있습니다. 이상값을 탐지하는 지표입니다. 모델 선택 기준입니다. 영향력 있는 예측치를 탐지하는 지표입니다. 회귀계수 추정: 먼저 모델을 만들고 계수를 추정함. 독립변수 검증: 다중공선성(VIF) 등을 검토함. 회귀모델 유의성검정: F-검정을 통해 모델의 유의성을 확인함. 회귀분석 모델 평가는 먼저 회귀계수를 추정하고, 모델의 유의성을 검증한 후, 개별 독립변수의 유의성을 검증하는 순서로 진행됩니다.
36. 다음은 기술 통계에서 사용하는 개념이다. 옳지 않은 것은? 1. 사분위수는 Q3-Q1이다. 2. 범위는 Min, Max 값만 고려한다. 3. 편차의 절대값이 크면 평균에서 멀리 떨어져 있는 값이고, 작으면 평균에서 가까운 값이다. 4. 일반적으로 표본의 수가 많을수록 표준오차는 작아진다.	49. 다음 수식에 대한 설명으로 옳은 것은? 49. 다음 수식에 대한 설명으로 옳은 것은? $\ln\left(\frac{P(Y=1 X)}{1-P(Y=1 X)}\right) = \beta_0 + \beta_1 X$ 1. X가 1단위 증가하면 오즈 값을 증가한다. 2. X가 1단위 증가하면 b 만큼 증가한다. 3. X가 1단위 증가하면 y만큼 증가한다. 4. X가 1단위 증가하면 e^y만큼 증가한다.	오즈비 = (오즈1 / 오즈2) * 100 = (0.25 / 0.0417) * 100 = 60 이 아니라 51입니다. 48. 흡연자 100명 중 폐암 20명, 비흡연자 100명 중 폐암 4명일 때 오즈비(Odds Ratio)는? • 흡연자 오즈: $\frac{20}{80} = 0.25$ • 비흡연자 오즈: $\frac{4}{96} = 0.0417$ • 오즈비(OR): $\frac{0.25}{0.0417} = 6$

1. 데이터셋을 k개로 분할 2. k-1개의 검증 데이터 확보 3. 학습 데이터와 검증 데이터를 서로 다르게 지정하여 k번 반복 4. k번 각각의 성능에 대한 평균을 도출	
65. 아래 보기에 대한 설명으로 옳은 것은? 두 명의 데이터 분석가 A와 B가 있다. A와 B는 각각의 방식으로 데이터를 분석하기로 했으며, 분석 시 10개의 파라미터를 동일하게 설정하기로 결정했다.	하나의 데이터를 검증에 사용하고 나머지로 학습하는 방식이라 해당 문맥과 맞지 않는다.
1. LOOCV	데이터가 매우 적을 때 사용된다.
2. 5fold-CV	5-Fold CV(2번)나 Stratified K-fold CV(4번)는 샘플링 기법이지만, 본 문제는 오월 비교보다는 데이터의 재표본추출을 강조하고 있으므로 Bootstrap(3번)이 적절하다.
3. Bootstrap	두 명의 데이터 분석가가 동일한 파라미터를 설정하고 데이터를 분석할 때, 5-fold 교차검증은 데이터를 5개로 분할하여 각각의 분할에 대해 학습과 검증을 반복하는 방법으로, 일반화 성능을 평가하는 데 적합합니다. A와 B가 같은 파라미터 설정을 사용한다는 점에서 재표본추출(Resampling) 기법인 <Bootstrap>이 적절하다.
4. Stratified K-fold CV	데이터를 반복적으로 샘플링하는 방법으로, 교차검증과는 다릅니다.
66. 콜모고로프-스미르노프(K-S) 통계량에 대한 설명으로 옳은 것을 모두 고르시오. 가, 서로 다른 두개의 집단이 동일한 분포를 이루고 있는지를 검증하는 지표 나, 비교하는 두 개의 집단 사이의 최대 거리 다, 누적분포함수(Cumulative Distribution Function, CDF)와 경험적 누적분포함수(Experience CDF 혹은 ECDF)를 사용	콜모고로프-스미르노프(K-S) 검증은 두 분포가 동일한지를 검증하는 방법이며, 누적분포함수(CDF)와 경험적 누적분포함수(ECDF)를 활용하여 두 분포 간 최대 거리를 계산한다.
1. 가 2. 가, 나 3. 나, 다 4. 가, 나, 다	
67. 다음 중 적합도 검증에 대한 설명으로 옳지 않은 것은? 1. 모델 전체의 적합성은 검증 불필요하다. 2. 적합도 검증(Goodness-of-Fit Test)은 이 데이터가 특정 이론적 분포와 일치하는지를 검증하는 방법이다. 3. 정규분포를 가정 시 정규성 검정을 가장 많이 활용하고 있다. 4. 정규분포를 가정하지 않을 시 카이제곱 검정을 이용해 적합도를 판단한다.	
68. 데이터 분할(Split)에 대한 설명으로 옳지 않은 것은? 1. 학습 데이터(훈련 데이터)보다 검증 데이터에서 성능이 좋은 하이퍼파라미터를 선정한다. 2. 테스트 데이터로 모델 간 성능을 비교한다. 3. 학습 데이터로 학습한다. 4. 데이터셋을 학습 데이터 검증 데이터, 테스트 데이터로 나누는 것이 적절하다.	학습 데이터보다 검증 데이터에서 성능이 좋은 하이퍼파라미터를 선정하는 것은 일반적이지 않다. (학습 데이터에서 검증 데이터보다 성능이 더 좋은 것이 보통이며, 과적합을 방지하는 것이 목적)
69. 다음 중 하이퍼파라미터 대한 설명으로 옳지 않은 것은? 1. 파라미터와 하이퍼파라미터는 학습 전에 결정다. 2. 하이퍼파라미터는 학습 과정 자체를 제어한다. 3. 하이퍼파라미터는 사람이 직접 입력값을 설정해줘야 한다. 4. 서로 다른 하이퍼파라미터값은 모델 학습과 정확도(Accuracy) 혹은 모델의 수렴율(Convergence Rate)에 영향을 미칠 수 있다.	파라미터(Parameter)는 학습 후 결정되지만, 하이퍼파라미터(Hyperparameter)는 학습 전에 설정해야 한다.
70. 하이퍼파라미터 최적화 기법에 대한 설명으로 옳지 않은 것은? 1. 수동탐색(Manual Search)은 사용자가 사전지식을 가지고 있다. 2. 무작위탐색(Random Search)는 다양한 조합들을 시험해 예상치 못한 결과를 얻을 수 있다. 3. 베이지안 최적화(Bayesian Optimization)는 새로운 하이퍼파라미터값에 대한 조사할 수행할 때에 사전지식 을 충분히 반영한다. 4. 그리드 분석기의 경험에 따라 값을 조절하는 게 최적이지만, 자동화를 위해 격자탐색(Grid Search) 등을 수행 한다.	베이지안 최적화는 사전지식을 반영하는 것이 아니라, 이전 실험 결과를 바탕으로 다음 하이퍼파라미터 값을 선택하는 방법입니다.
71. 다음 중 파라미터 최적화 기법이 아닌 것을 고르시오 1. RMSProp 2. AdaDelta 3. Nadam 4. Bayesian Optimization	*격자탐색(Grid Search) 등을 수행한다*는 자동화 기법이지만, ***경험에 따라 값을 조절하는 것이 최적***이라는 표현은 일반적으로 적용되지 않는다.
72. 랜덤포레스트 기법에 대한 설명으로 옳지 않은 것은? 1. 각각의 트리는 과적합 가능성이 있다. 2. 다수의 결정트리의 결과들 통해 최종결과를 도출한다. 3. 각각의 결정나무에 배깅과 같은 방법을 사용한다. 4. 전체 데이터셋으로 학습한다.	배깅(Bagging) 기법을 활용하여 여러 개의 결정트리를 학습하며, 전체 데이터셋을 하나의 트리에 학습하지 않는다.
73. 부스팅(Boosting)에 대한 설명으로 옳지 않은 것은? 1. 약학습기(Weak Learner)로 만든다. 2. 병렬로 학습한다. 3. 오답에 대한 가중값을 부여해 사용한다. 4. 보팅(Voting)과 함께 앙상블 학습유형으로 사용된다.	약한 학습기를 순차적으로 학습하는 방식으로 병렬 학습이 아니라 직렬 학습 방식이다.
74. 데이터에 대한 비즈니스 효과에 대한 설명으로 옳지 않은 것은? 1. 비즈니스 기여도는 데이터 분석결과를 활용하여 사업수행 혹은 과제수행 등을 통해 얻게 되는 긍정적인 영향 도를 의미한다. 2. 비즈니스 효과에 대한 정량적 가치 측정을 위해 각종 지표를 개발하였다. 3. 경영변화에 따라 비즈니스 효과 지표는 유연하게 변화한다. 4. 데이터의 가치(Value)는 부자요소, 속도와 규모는 비즈니스 효과를 나타낸다.	데이터의 속도와 규모는 비즈니스 효과가 아니라 빅데이터의 3V(Value, Velocity, Volume) 중 일부이다.
75. 시간시각화에 대한 설명으로 옳지 않은 것은? 1. 점그래프는 점의 집중도를 통해 표현하므로 시계열에 적합하지 않다. 2. 영역차트는 선 그래프와 그래프 축사이의 면적으로 데이터를 표시한 그래프이다. 3. 막대그래프는 범주의 수가 7개 이하일 때 주로 사용한다. 4. 묶은선그래프는 점그래프를 선으로 이은 것이다.	
76. 다음 중 x축(가로축)과 y축(세로축) 각각에 두 변수의 순서쌍을 점으로 표현해 두 변수의 관계를 나타낸 그래프는?	

7월	1. 산경도 2. 버플차트 3. 히스토그램 4. 플로팅바차트 77. 비교시각화 유형에 대한 설명으로 옳지 않은 것은? 1. 동행차트 그래프는 각 항목 변수별로 선을 매핑시켜 나타낸다. 2. 히트맵은 색상을 부여하는 방법이다. 3. 체르노프 페이스는 데이터를 얼굴로 표현한 방법이다. 4. 스타차트는 수치를 별의 개수로 표현하는 시각화 유형이다. 78. 다음 중 인포그래픽에 대한 설명으로 옳지 않은 것은? 1. 일부 인포그래픽은 특정 프로그램에서만 작동해 보기 위해서는 전문 소프트웨어가 필요하다. 2. 인포그래픽은 스토리텔링을 무조건 설치해야 한다. 3. 정보와 시각적 그래프의 합성어이다. 4. 그림 전체적으로 의미하는 바가 있어, 부분 전달이나 일부를 잘라서 적용할 경우 오해가 있을 수 있다. 79. 주제 연결성과 연관성 중심의 인포그래픽 유형은? 1. 도표형 2. 스토리텔링형 3. 비교분석형 4. 타임라인형 80. 다음 인포그래픽 유형 중 연도나 시간의 흐름에 따라 정보를 나열하기에 적합한 유형으로 알맞은 것은? 1. 타임라인 2. 도표형 3. 스토리텔링 4. 비교분석형		다각형 형태로 데이터를 표현하는 방식이며, 별의 개수로 데이터를 표현하지 않는다. 스토리텔링형 인포그래픽은 주제 연결성과 연관성 중심의 표현 방식이다. 연도나 시간 흐름을 나타내는 타임라인(Timeline) 인포그래픽이 적절하다. 데이터를 도표로 표현하는 유형입니다. 주제의 연결성과 연관성을 강조하는 유형입니다. 데이터를 비교하여 분석하는 유형입니다.
	01. 빅데이터의 특징 3가지로 옳은 것은? 1. 규모, 속도, 가치 2. 속도, 다양성, 가치 3. 규모, 다양성, 가치 4. 규모, 속도, 다양성 02. 다음 중 데이터가 처리되는 과정에서 변경되거나 손상되지 않고, 유지함을 보장하는 특성으로 알맞은 것은? 1. 데이터 완전성 2. 데이터 무결성 3. 데이터 정확성 4. 데이터 일관성 03. 기업분석 수준전단의 항목에 속하지 않는 것은? 1. 조직규모 2. 분석 데이터 3. 분석기법 4. IT인프라 04. 데이터 사이언티스트(데이터 과학자)가 가져야 할 소프트 스킬(Soft Skills)로 옳은 것은? 1. 통찰력 있는 분석 2. 전문지식 3. 통계기법 4. 알고리즘 05. 데이터 사이언스의 업무와 관계가 있는 것은? 1. 적합한 모델을 선정한다. 2. 가정의 한계를 고려한다. 3. 해석의 한계에서 벗어난다. 4. 분석 모델에 대한 한계점을 배제하고 진행한다. 06. 데이터 분석가의 특징 중 옳지 않은 것은? 1. 데이터 분석의 객관성을 위해 배경지식을 배제해야 한다. 2. 데이터를 다루는데 필요한 다양한 도구와 기술을 숙달해야 한다. 3. 데이터를 수집하고 분석하여 통찰력을 얻어야 한다. 4. 데이터 분석결과를 다른 부서나 팀원에게 효과적으로 전달하고 설명할 수 있어야 한다. 07. 하둡 분산파일시스템 (Hadoop Distributed File System, HDFS)의 설명으로 옳은 것은? 1. 여러 데이터를 한 곳에 저장할 수 있다. 2. 볼륨당 10MB이하의 제한이 있다. 3. 병용 하드웨어보다는 고성능 컴퓨터를 주로 사용한다. 4. 네임노드가 없기하면 정상적인 작동을 못한다. 08. 다음 중 빅데이터 플랫폼 계층구조의 설명으로 옳지 않은 것은? 1. 소프트웨어 계층, 플랫폼 계층, 인프라스트럭처 계층이 있다. 2. 소프트웨어 계층은 앱과 관련이 있다. 3. 플랫폼 계층은 데이터 제공 관리를 한다. 4. 인프라스트럭처 계층은 데이터 수집, 저장, 검색을 한다. 09. 데이터 3법이 해당하지 않는 것은?		기업 분석 수준 전단은 데이터, 분석 기법, IT 인프라 등의 요소를 평가하지만 조직 규모는 직접적인 분석 대상이 아니다. 데이터 분석은 해석의 한계를 벗어나지 않고 과학적 근거를 바탕으로 수행해야 한다. 분석 모델의 한계를 배제하는 것은 위험한 접근 방식 데이터 사이언티스트는 분석 모델의 한계점을 이해하고 이를 고려하여 업무를 진행해야 합니다. 한계점을 배제하고 진행하는 것은 잘못된 접근입니다. 분산 저장 HDFS는 대규모 데이터를 분산 저장하고 관리할 수 있는 시스템으로, 여러 데이터를 한 곳에 저장할 수 있습니다. 64MB 이상 병용 하드웨어 사용 HDFS에서 네임노드(NameNode)는 파일 시스템 메타데이터를 관리하는 중요한 역할을 한다. 플랫폼 계층은 데이터 처리 및 분석을 담당하며, 데이터 제공 관리는 인프라 계층의 역할이다. 인프라스트럭처 계층은 데이터 수집, 저장, 검색을 담당하지 않습니다. 이는 플랫폼 계층의 역할입니다. 데이터 3법은 개인정보보호법, 정보통신망법, 신용정보법을 포함한다.

1. 개인정보보호법	
2. 정보통신망이용촉진 및 정보보호 등에 관한 법률	
3. 공공데이터공개 및 이용 활성화에 관한 법률	
4. 신용정보이용 및 보호에 관한 법률	
10. 다음 중 데이터 일부 또는 전체를 식별할 수 있도록 노이즈나 공격 등으로 대체하는 것은?	개인정보를 다른 값으로 대체하는 기술입니다. 데이터를 집계하여 개별 데이터를 식별할 수 없도록 하는 기술입니다.
1. 가명처리	
2. 총계처리	
3. 데이터병주화	
4. 데이터 마스킹	
11. 다음 중 분석기획에서 우선순위 고려요소가 아닌 것은?	
1. 중요도	
2. ROI	
3. 분석가능성	
4. 분석 데이터 리소스 수준	석기획의 우선순위 고려 요소에는 중요도, ROI(투자 대비 수익), 분석 가능성이 포함된다.
12. CRISP-DM 절차에 대해 옳은 것은?	
1. 데이터 이해 - 업무 이해 - 전개 - 평가	
2. 데이터 이해 - 업무 이해 - 평가 - 전개	
3. 업무 이해 - 데이터 이해 - 평가 - 전개	
4. 업무 이해 - 데이터 이해 - 전개 - 평가	
13. 빅데이터 분석기획 단계에서 하는 일이 아닌 것은?	데이터 준비는 분석기획이 아닌 분석 수행 단계에서 이루어진다.
1. 데이터 준비	
2. 위험요인 계획	
3. 설계 및 계획	
4. 비즈니스 이해	
14. 다음 중 비정형 데이터가 아닌 것은?	
1. 동영상 파일	
2. 오디오 파일	
3. 문서	
4. 판매가격 데이터	
15. 반정형 데이터는 데이터의 형과 일로 구조화되어 있지는 않으나 스키마 및 메타데이터 특성을 가지고 있다. 다음 중 반정형 데이터에 해당되지 않는 것은?	
1. HTML	
2. XML	
3. RDB	RDF는 Resource Description Framework의 약자로, 자원의 정보를 표현하고 교환하기 위한 언어 규칙
4. RDF	
16. 개인정보 비식별화 기술로 수치적 개인정보를 임의의 수 기준으로 유평 또는 내림하는 기법은?	
1. 암호화	
2. 랜덤라운딩	랜덤라운딩은 데이터를 특정 기준으로 올림 또는 내림하는 기법이다.
3. 임의 값증 추가	
4. 식별자 삭제	
17. 다음 중 정형 데이터 품질검증방법으로 옳지 않은 것은?	
1. 진단 대상 정의 : 품질 이슈에 대한 수요 및 현황을 조사해 품질 진단 대상 데이터베이스를 선정하고, 진단 방향성을 정의	
2. 품질 진단 실시 : 대상에 대한 상세 수준의 품질 진단 계획 수립 후 품질 진단 영역별 진단을 실시	
3. 진단 결과 분석 : 오류 원인 분석, 업무 영향도 분석을 통해 개선 조치를 정의	
4. 업무규칙 : 진단 비즈니스 특성만 알 수 있고, 데이터 오류는 검증 못함	업무 규칙은 데이터 오류 검증에도 사용된다.
18. 데이터 누락 시 다음 데이터 품질 특성 중 어떤 성질을 만족 못하는가?	
1. 일관성	
2. 정확성	
3. 적시성	
4. 완전성	
19. 다음 중 오토샤딩(Auto-Sharding)을 사용하며, 처리속도가 빠른 NoSQL DB의 종류는?	
1. Cassandra	
2. MongoDB	
3. Redis	
4. Couchdb	
20. 분석 마스터플랜 수립에서의 범위 및 방식의 고려요소로 옳지 않은 것은?	분석 마스터플랜 수립에서 분석 데이터 적용 수준은 고려요소가 아닙니다. 대신 실행용이성, 기술 적용 수준, 업무 내재화 적용 수준 등을 고려합니다.
1. 분석 데이터 리소스 수준	
2. 실행용이성	
3. 기술 적용 수준	
4. 업무 내재화 리소스 수준	
21. 데이터 전처리 방법으로 옳지 않은 것은?	
1. 레거시 시스템으로만 전처리를 진행해야 한다.	
2. 비정형 데이터는 정제를 진행해야 한다.	
3. 전처리 시 삭제 및 수정 진행이 가능하다.	
4. 데이터를 통합하여 정제를 진행할 수 있다.	
22. 다음 중 데이터 정제 방법으로 옳은 것은?	
1. 데이터 손실을 최소화하기 위해 누락된 데이터를 임의로 채운다.	
2. 구분자가 포함되어 있을 수 있으니 처리해야 한다.	
3. 이상치 데이터를 모두 제거한다.	
4. 단일 데이터 포인트를 기반으로 모든 데이터를 수정한다.	

4. 시계열적 (Time-series)	
17. 다음 중 분산파일시스템으로 옳지 않은 것은? 1. Hbase 2. Ceph 3. HDFS 4. GFS	분산 데이터베이스 시스템이며, 분산 파일 시스템이 아닙니다.
18. Key-value 데이터 베이스에 대한 설명으로 가장 옳지 않은 것은? 1. 키와 값으로 이루어짐 2. 같은 모든 유형의 데이터로 저장 가능 3. 관계나 복잡한 쿼리 처리 유용 4. 주로 빠른 읽기 및 쓰기 작업에 최적화	Key-value 데이터베이스는 간단한 키-값 쌍을 저장하는 데 적합하며, 복잡한 쿼리 처리에는 적합하지 않습니다.
19. 다음 중 MongoDB, Cassandra DB와 같이 반정형, 비정형 데이터를 처리하기에 적합한 데이터베이스는? 1. In-memory DB 2. DFS 3. NoSQL 4. RDBMS	메모리 기반 데이터베이스로, 반정형/비정형 데이터 처리와는 직접적인 관련이 없습니다. 분산 파일 시스템으로, 데이터베이스와는 다른 개념입니다.
20. 다음 중 결측값 대체에 대한 설명으로 가장 옳지 않은 설명은? 1. 결측값을 분산/평균 등으로 대체하면 분산이 감소한다. 2. 연속형 변수의 결측값을 대체할 때는 평균 또는 중앙값을 활용할 수 있다. 3. 범주형 변수의 결측값을 대체할 때는 최빈값을 사용할 수 있다. 4. 자기회귀로 결측값을 대체하면 상관성이 낮아지고 분산이 커진다.	자기회귀로 결측값을 대체하면 상관성이 높아지고 분산이 작아지는 경향이 있습니다.
22. 파생변수에 대한 설명으로 가장 옳지 않은 것은? 1. 시점에 따라 파생변수를 생성할 수 있다. 2. 상관 정도에 따라 파생변수를 고려한다. 3. 설명변수, 독립변수의 교호작용에 의해서 생성할 수 있다. 4. 특정 조건의 파생변수를 만들 수 있다.	파생변수는 기존 변수를 조합하거나 변형하여 생성하는 변수로, 상관 정도에 따라 고려하는 것이 아니라 데이터의 특성이나 분석 목적에 따라 생성됩니다.
23. 다음 중 음수 데이터는 불가능하여, 양수 데이터로 정규분포에 근사하게 변환하는 방법은? 1. Min-Max 정규화 2. Z-score 표준화 3. 구간화(Binning) 4. Box-Cox 변환	데이터를 구간으로 나누는 방법으로, 음수 데이터를 양수로 변환하지는 않습니다. Box-Cox 변환은 데이터를 양수로 변환하여 정규분포에 근사하게 만드는 방법입니다.
24. 표준화에 대한 설명으로 알맞은 것은? 1. 두 개 이상의 데이터를 합쳐서 하나의 데이터로 표현하는 것이다. 2. 노이즈를 제거해서 미끄럽게 한다. 3. 데이터를 특정 범위로 변환하여 데이터 간의 크기 차이를 줄이는 것이다. 4. 표준화한 값에는 단위가 없다.	데이터 병합 데이터 스무딩 정규화 표준화는 데이터를 평균 0, 표준편차 1로 변환하여 단위를 제거합니다.
25. 다음 중 데이터 경제 과정 중 변환에 대한 사례로 가장 옳지 않은 것은? 1. 날짜 데이터 (2022년 1월3일) - YYYY/MM/DD 2. 연령 데이터(11,24,33,38) - 10대, 20대, 30대로 범주화 3. 키 데이터(170, 165, 153,152) - 평균 키를 0으로, 표준편차를 1로 표준화 4. 다량의 이메일 목록 - 작은 그룹으로 배치	이메일 목록을 작은 그룹으로 배치하는 것은 데이터 분할에 해당하며, 데이터 변환과는 직접적인 관련이 없습니다.
26. 불균형 데이터에 대한 설명으로 옳지 않은 것은? 1. 불균형 데이터에서는 주로 소수 클래스의 샘플 수가 매우 적다. 2. 시각화하여 산포도를 그려볼 수 있다. 3. 상자그림을 통해 데이터의 분포와 이상값을 확인할 수 있다. 4. 소수 클래스를 먼저 샘플링하여 해결한다.	소수 클래스를 먼저 샘플링하는 것은 데이터의 정보 손실을 초래할 수 있으며, 일반적으로 오버 샘플링이나 다른 기법을 사용합니다.
27. 다음 중 서열적도 변수를 간의 상관관계를 측정할 때 사용하는 값은? 1. 피어슨 상관계수(Pearson) 2. 점 양분 상관계수(Point-biserial) 3. 스피어만 상관계수(Spearman) 4. 피아계수(Phi)	
28. 알 발생률과 개산의 상관관계를 다른 변수를 제외하고 분석하고 싶을 때 사용하는 기법은? 1. 군집분석 2. 편상관분석 3. F분포 4. 카이제곱	그룹화 편상관분석은 다른 변수의 영향을 제거하고 두 변수 간의 순수한 상관관계를 분석하는 데 사용됩니다. 분산분석(ANOVA)에서 사용 범주형 데이터의 독립성 검증
29. 단일변이면서 우측으로 꼬리가 긴 분포의 대표값에 대한 설명으로 옳은 것은? 1. 평균 < 최빈값 < 중앙값 2. 최빈값 < 중앙값 < 평균 3. 중앙값 < 최빈값 < 평균 4. 최빈값 < 평균 < 중앙값	
30. 데이터의 설명 현상이나 분포 비대칭성을 확인할 수 있는 가장 알맞은 기법은? 1. 분산(Variance) 분석 2. 왜도(Skewness) 3. 첨도(Kurtosis) 4. 히스토그램(Histogram) 분석	
31. 다음 중 경수가 각각 60, 70, 80일 때 표본분산으로 옳은 것은? 1. 10	

2. 20	
3. 100	
4. 200	
32. A그룹은 100명 중 71명 투표, B그룹은 200명 중 134명 투표했을 때, 모평균 pA와 pB에 대해 pA - pB값의 추정치로 옳은 것은?	
1. 0.04	
2. 1.38	
3. 0.67	
4. 0	두 그룹의 투표 비율이 동일하므로 ($71/100 = 0.71$, $134/200 = 0.67$), PA - pB는 0에 가깝습니다.
33. 다음 중 기초 통계량과 그래프로 확인할 수 없는 것은?	
1. 통계적 유의성	통계적 유의성은 가설검정을 통해 확인되며, 기초 통계량이나 그래프로는 확인할 수 없습니다.
2. 결측값	
3. 이상값	
4. 데이터 분포	
34. 모자이크 플롯(그림)에 대한 설명으로 적절하지 않은 것은?	
1. 히스토그램 안에 히스토그램을 겹쳐 그릴 것이다.	모자이크 플롯은 범주형 변수 간의 관계를 시각화하는 데 사용되며, 히스토그램을 겹쳐 그리는 것과는 관련이 없습니다.
2. 상대적인 빈도 차이나 구조를 시각적으로 파악한다.	
3. 범주형변수 간의 관계를 시각화한다.	
4. 직사각형 면적 하나가 빈도를 나타낸다.	
35. 기술 통계량으로 옳지 않은 것은?	
1. 최대값	
2. 중앙값	
3. 이상값	이상값은 데이터의 특이점을 나타내는 것이며, 기술 통계량에 포함되지 않습니다.
4. 분산	
36. 다음 중 샘플링 기법이 아닌 것은?	
1. Metropolis-Hastings Algorithm	
2. Perfect Sampling	
3. EM Algorithm	EM 알고리즘은 결측값 처리나 모수 추정에 사용되는 알고리즘이며, 샘플링 기법이 아닙니다.
4. Rejection Sampling	
38. 모집단에서 표본 N을 추출하여 표본평균의 분포를 구할 때 옳지 않은 것은?	
1. N 갯수(표본크기)와 상관없이 표본평균은 모집단의 평균에 수렴한다.	
2. 표본평균은 모집단의 기대값을 의미한다.	
3. N 크기가 커지면 표본평균의 분산은 커지고, 표준편차는 작아진다.	N 크기가 커지면 표본평균의 분산은 작아지고, 표준편차도 작아집니다.
4. N 크기가 커지면 표준오차는 작아진다.	
39. 다음 보기의 설명으로 옳은 것은?	
동일한 확률분포를 가진 독립확률변수 n개의 평균의 분포는 n이 커질수록 크면 정규분포에 가까워진다는 이론	
1. 중심극한정리	
2. 대수의 법칙	
3. 카이제곱검정	
4. t-분포	
41. 모델의 배치에 관한 설명으로 옳지 않은 것은?	
1. 배치의 크기가 커지면 학습시간은 오래 걸리지만, 정확성에는 영향을 끼치지 않는다.	치 크기가 커지면 학습 시간이 줄어들지만, 정확성에도 영향을 미칠 수 있습니다.
2. 배치크기는 학습속도에 영향을 주지만, 학습성능에는 영향을 끼치지 않는다.	
3. 배치크기가 너무 크면 메모리 문제가 발생한다.	
4. 배치크기가 작으면 노이즈를 반영하여, 모델의 학습에 악영향을 줄 수 있다.	
42. 모델의 편향과 분산 관계에 대한 설명으로 적절함 것은?	
1. 좋은 모델은 편향이 작고 분산도 작다.	분산이 크면 모델이 과적합될 가능성이 높습니다. 편향과 분산은 서로 관련이 있습니다.
2. 좋은 모델은 편향이 크고 분산도 작다.	
3. 좋은 모델은 편향이 작고 분산도 크다.	
4. 모델의 편향과 분산은 서로 독립적이다.	
43. 다음 중 가중치 제곱합을 최소화하는 제약을 주는 기법으로 옳은 것은?	
1. 라쏘회귀	가중치의 절대값 합을 최소화하는 제약을 줍니다.
2. 릿지회귀	라쏘와 릿지의 결합으로, 가중치의 절대값과 제곱합을 모두 고려합니다. 분류 문제에 사용되며, 가중치 제곱합 최소화와는 직접적인 관련이 없습니다.
3. 엘라스넷	
4. 로지스틱회귀	
44. 다중공선성의 설명으로 옳은 것은?	
1. 독립변수들 간의 상관성을 나타내는 값으로, 분산관계를 나타낸다.	부분적으로 맞지만, 주된 설명은 아닙니다.
2. 독립변수들 간의 상관성을 나타내는 값으로, 변수들 모델에 악영향을 미친다.	다중공선성은 독립변수 간의 상관성을 다룹니다. 다중공선성은 독립변수 간의 상관성을 다룹니다.
3. 종속변수들 간의 분산크기에 대한 상관계수이다.	
4. 종속변수들 간의 상관성을 나타내는 값으로, 작을수록 모델에 악영향을 미친다.	
45. 다음 중 결정계수(R²)에 대한 설명으로 옳은 것은?	
1. 독립변수가 종속변수에 의해 설명되는 오차의 비율을 나타낸다.	결정계수는 종속변수가 독립변수에 의해 설명되는 비율을 나타냅니다.
2. 범위는 보통 0과 1 사이에 있으며, 모델이 데이터를 얼마나 잘 설명하는지의 정도를 나타낸다.	결정계수는 종속변수와 독립변수 간의 관계를 나타냅니다. 결정계수는 단순선행회귀와 다중선행회귀 모두에서 사용됩니다.
3. 독립 변수개수의 관계를 나타낸 것이다.	
4. 다중선행회귀 모델에서는 1개만 존재한다.	
46. 선형 회귀분석과 로지스틱 회귀분석에 대해 설명으로 옳지 않은 것은?	
1. 모두 오차항의 가정이 필요하다.	로지스틱 회귀분석은 오차항의 가정이 필요하지 않습니다.
2. 선형 회귀분석에서의 정규성 가정은 잔차가 정규분포를 따른다는 것을 의미한다.	
3. 로지스틱 회귀분석은 종속 변수가 범주형인 경우에 사용한다.	
4. 모두 최대우도법으로 회귀계수를 추정한다.	

64. 실제 Positive인 경우에 Positive로 예측한 것은? 1. 정확도 2. 정밀도 3. 지연율 4. 특이도	
66. 다음 중 ROC곡선에 대한 설명으로 옳지 않은 것은? 1. FPR 값에 따른 TPR 값 그래프이다. 2. FPR이 작아도 TPR이 클 수 있다. 3. 무작위의 경우 TPR과 FPR은 같은 곳으로 수렴한다. 4. AUC가 작을수록 모델 성능이 높다.	AUC(Area Under Curve)가 클수록 모델 성능이 좋습니다.
67. 교차검증에 대한 설명으로 가장 옳은 것은?? 1. 학습 데이터에서 일은 오류수정치가 검증 데이터보다 많이 적다면 과적합되어 있을 수 있다. 2. 시계열 데이터를 사용하기 용이하다. 3. 교차검증으로는 과적합을 해결할 수 없다. 4. 일반적으로 모델의 생성 시간이 매우 감소된다.	학습 데이터와 검증 데이터의 오류 차이가 크면 과적합 가능성이 높습니다.
68. 다음 중 K-fold교차검증에 대한 설명으로 옳지 않은 것은? 1. k-1개 데이터셋은 학습용, 1개 데이터셋은 검증용으로 사용한다. 2. 데이터셋은 홀수로만 나눈다. 3. 데이터셋은 k번 반복한다. 4. 데이터셋은 각각 한 번씩만 검증용으로 사용한다.	K-fold 교차검증은 데이터를 행과 열 모두로 나눌 수 있습니다.
69. 지도학습 모델의 역할도 검증에 대한 설명으로 옳지 않은 것은? 1. 자기상관성 2. 카이제곱검정 3. 사파로-윙크검정 4. 콜모고로프-스미르노프검정	자기상관성은 시계열 데이터 분석에 사용되며, 지도학습 모델의 적합도 검증과는 직접적인 관련이 없습니다.
71. 다음 중 과적합 방지 방안으로 옳지 않은 것은? 1. 규제항을 사용한다. 2. 예개변수를 늘린다. 3. 조기 종료한다. 4. 드롭아웃을 사용한다.	예개변수를 늘리면 모델이 복잡해져 과적합 가능성이 높아집니다.
72. 파라미터와 하이퍼파라미터에 대한 설명으로 옳지 않은 것은? 모두 맞음 1. 파라미터는 학습을 통해 최적화 가능하다. 2. 파라미터는 경사하강법으로 추정할 수 있다. 3. 하이퍼파라미터는 학습 중에 변하지 않는다. 4. 은닉층수와 학습률은 하이퍼파라미터의 사례이다.	하이퍼파라미터는 학습 중에 조정될 수 있습니다.
73. 경사하강법의 설명으로 옳은 것은? 1. 확률적 경사하강법은 전미분을 사용한다. 2. 모멘텀은 관성을 이용하여 지역최소점이 아닌 글로벌 최소점으로 구한다. 3. 아디그라드(Adaptive gradient)는 이전 기울기 값과 관계없다. 4. 아담(ADAM)은 학습률을 고정하지 않는다.	확률적 경사하강법은 미니배치를 사용함니다. 모멘텀은 관성을 이용하여 지역최소점을 벗어나 글로벌 최소점을 찾는 데 도움을 줍니다. 아디그라드는 이전 기울기 값을 고려함니다. 아담은 학습률을 고려함니다.
74. 다음 중 앙상블 기법에 대한 설명 중 적절하지 않은 것은? 1. 보팅 - 예측한 결과값을 다수의 분류기 투표로 결정 2. 랜덤포레스트 - 배깅과 부스팅보다 더 많은 무작위성을 주어 여러 개의 약한 학습기들을 생성하고 결합 3. 배깅 - 부트스트랩으로 데이터의 다양성을 확보하여 다양한 결과를 분류 및 예측 4. 스태킹 - 동일한 표본으로 다양한 유형의 모델을 학습	랜덤포레스트는 배깅 기법을 사용하며, 부스팅과는 다름니다.
75. 다음 중 데이터시각화 결과로 알맞은 것은? 1. 데이터 획득 - 구조화 - 모델 훈련 - 모델 성능평가 - 시각화 모델 선택 - 시각화 표현 및 재정의 2. 데이터 획득 - 모델 훈련 - 모델 성능평가 - 구조화 - 시각화 모델 선택 - 시각화 표현 및 재정의 3. 데이터 획득 - 시각화 표현 및 재정의 - 시각화 모델 선택 - 구조화 - 모델 훈련 - 모델 성능평가 4. 데이터 획득 - 구조화 - 시각화 모델 선택 - 시각화 표현 및 재정의 - 모델 훈련 - 모델 성능평가	
76. 국회의원 선거에서 지역 연적이 아니라 지역구에 당선된 국회의원 수에 따라 시각화하고자 할 때 적합한 시각화 도구가 옳은 것은? 1. 단계구분도 2. 등치선도 3. 격자 카토그램 4. 픽토그램	지역 연적에 따라 시각화하는 데 적합함니다. 지형적 높이에 따라 시각화하는 데 적합함니다.
77. 다음 중 지역 별 매출액과 수익율에 대해 나타내는 시각화 기법으로 가장 알맞은 것은? 1. 매출 - 카토그램, 수익 - 버블차트 2. 매출- 픽토그램, 수익 - 버블차트 3. 매출 - 카토그램, 수익 - 산점도 4. 매출 - 픽토그램, 수익 - 산점도	아이콘을 사용하여 데이터를 시각화하는 데 적합함니다.
79. 다음 중 인포그래픽에 대한 사례로 알 연결된 것 고르시오. (가) 지역별 코로나 발생률 (나) 월별 코로나 발생률 1. 가 - 지도형, 나 - 타임라인형 2. 가 - 지도형, 나 - 도표형 3. 가 - 스토리텔링형, 나 - 타임라인형 4. 가 - 스토리텔링형, 나 - 도표형	지역별 코로나 발생률은 지도형으로, 월별 코로나 발생률은 도표형으로 시각화하는 것이 적합함니다.
80. 분석 활동 계획에 대한 설명으로 옳지 않은 것은? 1. 이해관계자와 협의하여 계획을 수립한다.	

[illegible]

[illegible]

[illegible]

[illegible]

[illegible]

[illegible]

[illegible]

[illegible]

[illegible]

[illegible]

[illegible]

[illegible]